

基于物理信息强化学习的冗余自由度机械臂高效避障算法

Xie Yang

摘要—现有RL方法应用于7-DOF机械臂避障时存在两个问题：(1) 样本效率低，训练代价大；(2) 学出的策略容易违反物理约束（力矩突变、奇异位形等）。本文提出将物理先验嵌入RL框架，同时提升训练效率和策略物理可行性。

本文提出了一种基于强化学习的冗余机械臂零空间策略学习方法，旨在提高任务执行效率与运动协调性。实验结果表明所提方法在末端轨迹跟踪及关节冗余管理中具有明显优势。

1. 背景

冗余机械臂具有多解性

Null-space 用于执行次任务

2. 问题

传统方法依赖人工设计（**gradient / potential**）

难以处理复杂约束（避障、能耗、奇异性）

3. 方法（你的贡献）

提出：**RL 学习 Null-space policy**

与 **Jacobian** 解耦

4. 结果

提升：成功率 / 能耗 / **manipulability**

Index Terms—冗余机械臂，零空间策略，强化学习，轨迹规划

I. 引言

A. 背景

冗余机械臂（7DOF）广泛用于：人机协作复杂操作任务

Null-space 控制用于：多任务优先级控制避障 / 姿态优化

B. 问题陈述

传统方法：**z** 是 hand-crafted，无法处理复杂环境

已有工作：RL用于避障，但通常直接学 **joint control** 或没有结构约束

C. 论文贡献

贡献1：结构化 RL 框架：仅学习 **Null-space policy**

贡献2：与任务空间解耦的控制结构，不影响主任务，提高稳定性

贡献3：多目标 **reward**（成功率、能耗、**manipulability**）

II. 相关工作

相关工作涵盖经典逆运动学、优先级任务空间控制、以及近年强化学习在机械臂控制中的应用。

III. 方法

A. 问题定义

1) 任务目标：给定末端执行器期望轨迹 $x_d(t) \in SE(3)$ 和障碍物集合 $\mathcal{O}$ ，目标是学习一个零空间策略 $\pi: S \rightarrow \mathbb{R}^7$ ，使机械臂在跟踪末端轨迹的同时：

- 避免与障碍物碰撞
- 保持关节远离奇异位形
- 最小化能量消耗
- 满足关节位置、速度、力矩约束

2) 控制结构：采用分层控制架构：

$$\dot{q} = \dot{q}_{\text{task}} + \dot{q}_{\text{null}} \quad (1)$$

其中：

- $\dot{q}_{\text{task}} = J^\dagger(q)(\dot{x}_d + K_p(x_d - x))$ ：任务空间控制项，保证末端轨迹跟踪
- $\dot{q}_{\text{null}} = N(q)\pi(s)$ ：零空间策略输出，由RL学习

3) 强化学习形式化：将问题建模为马尔可夫决策过程（MDP） $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$ ：

状态空间 $\mathcal{S}$ ：

$$s_t = [q_t, \dot{q}_t, x_d, \dot{x}_d, d_{\text{obs}}, w(q_t)] \quad (2)$$

包含关节状态、期望轨迹、障碍物距离 d_{obs} 、可操作度 $w(q) = \sqrt{\det(JJ^T)}$

动作空间 $\mathcal{A}$ ：

$$a_t = \dot{q}_0 \in \mathbb{R}^7 \quad (3)$$

策略输出零空间内的自运动速度，实际关节速度为 $\dot{q}_t = J^\dagger \dot{x}_d + N(q_t)a_t$

奖励函数 $\mathcal{R}$ ：

$$r_t = r_{\text{track}} + r_{\text{obs}} + r_{\text{manip}} + r_{\text{energy}} \quad (4)$$

其中:

- $r_{\text{track}} = -\|x_t - x_d\|^2$: 末端跟踪误差
- $r_{\text{obs}} = -\exp(-d_{\text{obs}}/\sigma)$: 障碍物避障奖励
- $r_{\text{manip}} = w(q_t)$: 可操作度奖励
- $r_{\text{energy}} = -\|\tau_t\|^2$: 能量消耗惩罚

B. 机械臂动力学模型

考虑7自由度冗余机械臂, 其配置空间为 $q \in \mathbb{R}^7$, 末端执行器位姿为 $x \in SE(3)$ 。

1) 运动学关系: 正运动学映射为:

$$x = f(q) \quad (5)$$

末端速度与关节速度的关系由雅可比矩阵 $J(q) \in \mathbb{R}^{6 \times 7}$ 描述:

$$\dot{x} = J(q)\dot{q} \quad (6)$$

由于 $J(q)$ 为非方阵 (6行7列), 系统存在1维零空间, 即存在关节速度 $\dot{q}_{\text{null}}$ 满足:

$$J(q)\dot{q}_{\text{null}} = 0 \quad (7)$$

2) 动力学方程: 机械臂动力学遵循拉格朗日方程:

$$M(q)\ddot{q} + C(q, \dot{q})\dot{q} + g(q) = \tau \quad (8)$$

其中:

- $M(q) \in \mathbb{R}^{7 \times 7}$: 对称正定的惯性矩阵
- $C(q, \dot{q}) \in \mathbb{R}^{7 \times 7}$: 科氏力与离心力矩阵
- $g(q) \in \mathbb{R}^7$: 重力项
- $\tau \in \mathbb{R}^7$: 关节力矩输入

3) 零空间投影: 定义零空间投影矩阵:

$$N(q) = I_7 - J^\dagger(q)J(q) \quad (9)$$

其中 $J^\dagger = J^T(JJ^T)^{-1}$ 为Moore-Penrose伪逆。

任意关节速度可分解为任务空间分量与零空间分量:

$$\dot{q} = J^\dagger(q)\dot{x} + N(q)\dot{q}_0 \quad (10)$$

其中 $\dot{q}_0 \in \mathbb{R}^7$ 为零空间内的自运动速度, 不影响末端执行器运动。

C. 物理信息增强的策略网络

传统RL方法在学习机械臂控制策略时, 常出现力矩突变、违反动力学约束等问题。为提升策略的物理可行性, 本文在策略网络中嵌入动力学先验。

1) 动力学一致性约束: 机械臂动力学方程为:

$$\tau = M(q)\ddot{q} + C(q, \dot{q})\dot{q} + g(q) \quad (11)$$

其中 $M(q) \in \mathbb{R}^{7 \times 7}$ 为惯性矩阵, $C(q, \dot{q})$ 为科氏力与离心力项, $g(q)$ 为重力项。

策略网络输出关节加速度 $\ddot{q}_\pi$, 通过动力学模型计算对应力矩 τ_π 。定义动力学一致性损失:

$$\mathcal{L}_{\text{dyn}} = \|\tau_\pi - \tau_{\text{limit}}\|^2 \quad (12)$$

其中 τ_{limit} 为关节力矩约束边界的软投影。

2) 正则化损失 vs. *Reward Shaping*: 区别于将物理约束作为额外奖励项的reward shaping方法, 本文将动力学一致性约束以正则化损失的形式直接作用于策略网络。这一设计的理论优势在于:

- **保持最优性**: reward shaping改变原始MDP的奖励结构, 可能导致最优策略偏移 [1]; 正则化损失不改变RL优化目标, 仅对策略函数空间施加归纳偏置
- **训练稳定性**: 奖励项需要精细调参平衡任务奖励与约束惩罚; 正则化损失与策略梯度解耦, 超参数鲁棒性更强

最终策略网络的总损失函数为:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{RL}} + \lambda_{\text{dyn}}\mathcal{L}_{\text{dyn}} \quad (13)$$

其中 $\mathcal{L}_{\text{RL}}$ 为标准RL损失 (PPO或SAC), λ_{dyn} 为正则化系数。

D. 运动学引导的动作空间约束

运动学引导的动作空间约束— 利用7-DOF的雅可比零空间投影, 将RL的动作空间分解为任务空间分量+自运动分量, RL只需要学习零空间内的冗余分配策略, 大幅降低探索维度

E. 基于距离场的避障奖励

基于距离场的避障奖励— 用signed distance field (SDF) 计算机械臂各连杆与障碍物的距离, 作为密集奖励信号

IV. 实验

A. 实验设置

1) 对比方法: 为验证所提方法的有效性, 选取以下基线方法:

传统方法:

- **RRT***: 基于采样的运动规划
- **CHOMP**: 基于优化的轨迹规划

纯RL方法：

- PPO-Baseline: 无物理信息的标准PPO
- SAC-Baseline: 无物理信息的标准SAC

消融实验：

- Ours-Dynamics: 仅加入物理信息增强
- Ours-Nullspace: 仅加入零空间约束
- Ours-Full: 完整方法（物理信息+零空间+距离场奖励）

2) 测试场景: 设计三类典型场景评估算法性能:

- 场景1-稀疏障碍: 3-5个静态障碍物, 验证基本避障能力
- 场景2-密集障碍: 10+障碍物形成窄通道, 测试复杂环境适应性
- 场景3-动态障碍: 2-3个运动障碍物, 评估泛化性与实时性

3) 评价指标:

- 任务成功率: 100次测试中成功到达目标的比例
- 样本效率: 训练收敛曲线（达到90%成功率所需样本数）
- 路径质量: 路径长度、执行时间
- 物理可行性: 关节力矩平滑度（相邻时刻力矩变化率）
- 安全性: 最小障碍距离

B. 结果分析

1) 成功率对比:

2) 训练效率分析:

3) 物理可行性验证:

4) 消融实验结果: 本段示例引用: 如文献所示 [1]。

V. 结论

本文总结了所提方法的优点与未来改进方向。

参考文献

- [1] G. J. Pottie and W. J. Kaiser, "Embedding the internet: Wireless integrated network sensors," *Communications of the Acm*, vol. 43, 2000.