

基于路径模仿和SAC强化学习的机械臂路径规划算法

宋紫阳¹, 李军怀^{1,2}, 王怀军^{1,2*}, 苏鑫¹, 于蕾^{1,2}

(1. 西安理工大学 计算机科学与工程学院, 西安 710048; 2. 陕西省网络计算与安全技术重点实验室, 西安 710048)

(* 通信作者电子邮箱 wanghuaijun@xaut.edu.cn)

摘要:在机械臂路径规划算法的训练过程中,由于动作空间和状态空间巨大导致奖励稀疏,机械臂路径规划训练效率低,面对海量的状态数和动作数较难评估状态价值和动作价值。针对上述问题,提出一种基于SAC(Soft Actor-Critic)强化学习的机械臂路径规划算法。通过将示教路径融入奖励函数使机械臂在强化学习过程中对示教路径进行模仿以提高学习效率,并采用SAC算法使机械臂路径规划算法的训练更快、稳定性更好。基于所提算法和深度确定性策略梯度(DDPG)算法分别规划10条路径,所提算法和DDPG算法规划的路径与参考路径的平均距离分别是0.8 cm和1.9 cm。实验结果表明,路径模仿机制能提高训练效率,所提算法比DDPG算法能更好地探索环境,使得规划路径更加合理。

关键词:模仿学习; 强化学习; SAC算法; 路径规划; 奖励函数

中图分类号: TP241.2 **文献标志码:** A

Path planning algorithm of manipulator based on path imitation and SAC reinforcement learning

SONG Ziyang¹, LI Junhuai^{1,2}, WANG Huaijun^{1,2*}, SU Xin¹, YU Lei^{1,2}

(1. School of Computer Science and Engineering, Xi'an University of Technology, Xi'an Shaanxi 710048, China;

2. Shaanxi Key Laboratory for Network Computing and Security Technology, Xi'an Shaanxi 710048, China)

Abstract: In the training process of manipulator path planning algorithm, the training efficiency of manipulator path planning is low due to the huge action space and state space leading to sparse rewards, and it becomes challenging to evaluate the value of both states and actions given the immense number of states and actions. To address the above problems, a robotic manipulator planning algorithm based on SAC (Soft Actor-Critic) reinforcement learning was proposed. The learning efficiency was improved by incorporating the demonstrated path into the reward function so that the manipulator imitated the demonstrated path during reinforcement learning, and the SAC algorithm was used to make the training of the manipulator path planning algorithm faster and more stable. The proposed algorithm and Deep Deterministic Policy Gradient (DDPG) algorithm were used to plan 10 paths respectively, and the average distances between paths planned by the proposed algorithm and the DDPG algorithm and the reference paths were 0.8 cm and 1.9 cm respectively. The experimental results show that the path imitation mechanism can improve the training efficiency, and the proposed algorithm can better explore the environment and make the planned paths more reasonable than DDPG algorithm.

Key words: imitative learning; Reinforcement Learning (RL); Soft Actor-Critic (SAC) algorithm; path planning; reward function

0 引言

工业机器人的规模化应用提高了工业和制造业等行业的生产效率。机械臂是机器人的主要形式之一,通过运动副的转动或移动使机械臂末端运动到合适的位置和姿态,完成不同的工作任务。机械臂具有较高的自由度,能部署在不同场景下,快速执行作业任务。机器学习(Machine Learning)技术可以提高机器人的智能化水平,让机器人拥有自主决策与学习能力,在机器人轨迹路径规划^[1-2]、环境感知^[3-4]和智能决

策与控制^[5-6]等方向都有应用。强化学习克服了传统机械臂控制方法对环境状态变化适应能力差的缺点,成为机械臂智能化研究的重要方向^[7-8]。

目前,基于强化学习的机械臂路径规划面临两个问题:1)机械臂的动作维度高、环境状态复杂,强化学习面对海量的状态数量和动作数量较难进行价值评估;2)奖励稀疏的问题,即当机械臂到达指定位置时才能得到奖励,导致训练时间长,效果较差。

在基于强化学习的机械臂路径或轨迹规划等方面,国内

收稿日期:2023-02-16;修回日期:2023-04-24;录用日期:2023-04-24。 基金项目:国家重点研发计划项目(2018YFB1703003);陕西省重点研发计划项目(2022SF-353);西安市科技计划项目(2022JH-RYFW-0072)。

作者简介:宋紫阳(1998—),男,山西临汾人,硕士研究生,主要研究方向:物联网、行为识别; 李军怀(1969—),男,陕西宝鸡人,教授,博士,CCF高级会员,主要研究方向:物联网、行为识别、网络计算; 王怀军(1981—),男,山东滕州人,副教授,博士,主要研究方向:智能感知、行为识别、智能制造; 苏鑫(1994—),男,陕西西安人,硕士研究生,主要研究方向:物联网; 于蕾(1976—),女,吉林长岭人,讲师,硕士,主要研究方向:物联网、计算机网络。

外学者已经有了一定的研究成果。

基于深度强化学习(Deep Reinforcement Learning, DRL)的机械臂路径规划。DRL使用深度神经网络(Deep Neural Network, DNN)近似价值函数或策略函数,较好地解决了环境状态与动作维度高、数量庞大,数据特征难以在有限的计算机内存中存储、计算和表达等问题。谷歌公司的DeepMind团队^[9]改进了DQN(Deep Q-Network)方法,提出了具有竞争网络结构的DQN方法(Dueling DQN),提高了DNN对价值函数拟合的准确性,但在面对连续控制问题时无法得到最优控制策略。Gu等^[10]提出归一化优势函数(Normalized Advantage Functions, NAF)方法,在DQN的基础上拓展了对连续控制问题的支持。Prianto等^[11]为了解决高维路径规划问题,提出了基于SAC(Soft Actor-Critic)的路径规划算法,为了有效处理构型空间中的多臂问题,扩充了各臂的构型空间,采用后见经验重放(Hindsight Experience Replay, HER)方法提高样本效率,可以实时、快速地生成任意起始点和目标点的最短路径。本文在文献[11]的基础上,设计特殊的奖励函数指导智能体学习如何选择最优行为,进一步扩展SAC强化学习的Critic部分,采用两个Q网络和两个目标Q网络对机械臂的路径规划设计进行优化,以达到更快速强化学习的目的。张永梅等^[12]基于DRL算法对连续型动作输出的端到端机器人路径规划进行研究,提出了内在好奇心驱动的深度确定性策略梯度算法,实现了端到端的机器人路径规划,有利于解决训练前期奖励难获取问题。

自从模仿学习被提出,它已被应用于机械臂路径规划。模仿学习被用于结合深度学习训练机械臂路径控制模型,或与强化学习结合训练得到路径规划的最优策略。于建均等^[13]通过拖动机械臂的方式得到示教路径,基于模仿学习和DNN实现机械臂对示教路径的快速学习,解决了机械臂动作规划编程复杂的问题。Rahmatizadeh等^[14]结合了长短期记忆(Long Short-Term Memory, LSTM)网络和混合密度网络(Mixture Density Network, MDN)作为机械臂的控制器,基于深度相机Kinect获取示教路径,通过模仿学习使机械臂合理规划路径完成物品的拾取和放置。加州大学Finn等^[15]使用逆最优控制(Inverse Optimal Control, IOC)训练机械臂路径规划,通过优化奖励函数引导价值对示教路径进行模仿学习,使机械臂学会了合理规划路径摆放盘子。使用示教路径优化奖励函数可以对智能体在训练过程中策略输出的动作作出更好的评价。汤自林等^[16]基于模仿学习提出了变刚度协作搬运控制策略,使用任务参数化的高斯混合模型(Task Parameterized Gaussian Mixture Model, TP-GMM)对示教路径编码,学习不同搬运工况下的搬运轨迹概率模型,提高了特定搬运任务的终点位置精度。

合理的机械臂运动路径是机械臂系统实现运动控制功能和完成任务的基础,本文提出一种基于路径模仿和SAC强化学习的机械臂路径规划算法。通过将机械臂末端的示教路径和实际路径融入奖励函数,使机械臂在强化学习过程中模仿示教路径纠正实际路径,提高学习效率,选择SAC算法作为强化学习方法使训练收敛更快且更稳定。

1 机械臂路径规划基本原理

针对强化学习在机械臂路径规划中奖励稀疏难以收敛的问题,引入对参考路径的模仿学习,根据机械臂运行的实际路径与参考路径的差异设计适当的奖励方式,实现快速强

化学习的目的。基于模仿学习的机械臂运动控制方法可分为示教路径的获取和示教路径的学习两个阶段。将手拖动机械臂所检测到的手部路径作为示教路径,在人拖动机械臂的过程中,机械臂通过编码器获取关节角度后通过正运动学方法解出机械臂的末端路径,将末端路径作为示教对象。基于SAC强化学习的机械臂路径规划算法原理如图1所示。




图1 机械臂路径规划算法原理

Fig. 1 Principle of manipulator path planning algorithm

SAC算法基于Actor-Critic框架,使用了5个DNN和1个经验回放池完成强化学习任务。5个DNN分为两组:一组包含一个策略网络,是SAC强化学习算法的Actor部分;另一组包含两个Q网络和两个目标Q网络,是SAC强化学习的Critic部分。奖励函数根据实际路径和参考路径的距离来计算奖励或者惩罚。SAC算法将机械臂状态和奖励函数的输出作为输入,向机械臂反馈下一步的动作。

2 路径模仿的奖励函数计算方法

机械臂SmallRobotArm选择六自由度,机械臂末端连接一个电磁铁。设定机械臂路径规划任务为拾取硬币并将硬币置入杯中。奖励函数根据机械臂的当前状态 s_t 和下一步要执行的动作 a_t 计算机械臂的任务完成度,根据任务完成度和机械臂末端与参考路径的距离计算奖励或者惩罚,诱导机械臂学习参考路径。

1) 机械臂状态模型。

在机械臂路径规划任务背景下定义环境状态, t 时刻的状态 $s_t \in S$ 是一个四元组: $s_t = (\text{pos}_t, \text{quat}_t, c, w)$,其中 pos_t 表示 t 时刻时机械臂末端在空间中的位置: $\text{pos}_t = (x_t, y_t, z_t)$, quat_t 表示机械臂末端效应在空间中的姿态角: $\text{quat}_t = (w_t, x_t, y_t, z_t)$, c 表示硬币在空间中的位置, w 表示水杯在空间中的位置。

2) 机械臂动作模型。

机械臂的动作 $a_t \in A$ 由3个部分构成: $a_t = (\Delta P_t, \Delta O_t, g_t)$, ΔP_t 和 ΔO_t 的表达式分别为 $\Delta P_t = (\Delta x_{pt}, \Delta y_{pt}, \Delta z_{pt})$, $\Delta O_t = (\Delta x_{ot}, \Delta y_{ot}, \Delta z_{ot})$,其中 ΔP_t 表示机械臂末端在 t 时刻移动位移的向量, ΔO_t 表示机械臂末端在 t 时刻的转动姿态角, g_t 表示机械臂末端的电磁铁在 t 时刻是否接通了电源。

3) 奖励函数模型。

奖励函数反映了在状态 s_t 下进行动作 a_t 的奖励的预期,可表示为:

$$R(s_t, a_t) = \mathbb{E}_\pi [R_{t+1} | s_t = s, a_t = a] \quad (1)$$

由于系统状态空间大,很难为所有状态设置奖励,奖励稀疏的问题导致学习缓慢甚至无法学习。为了使机械臂能快速学习针对任务的最优路径,通过特殊设计的奖励函数使机械臂对参考路径模仿学习,提高机械臂路径规划的学习速度和任务执行成功率。

将用手拖动机械臂获得的末端路径作为机械臂学习的参考路径,参考路径如图1所示。

定义机械臂在 t 时刻的任务完成度为 p_t :

$$p_t = \frac{t \text{时刻过程路径的长度}}{\text{参考路径总长度}} \quad (2)$$

根据任务要求,奖励或惩罚可分成3种情况:

①若机械臂完成将硬币置入水杯中的任务可得到最大奖励;未完成任务时不奖励。

②当机械臂末端沿着参考路径的方向运动时得到奖励;当机械臂沿着参考路径的反方向运动时奖励值为负,即受到惩罚。

③机械臂末端与参考路径的距离越近受到奖励越大;距离过远则会受到惩罚,距离越远惩罚越大。

根据上述分析,执行动作 a_t 后的奖励为:

$$R_{t+1} = \begin{cases} 5, & \text{任务完成} \\ (p_t - p_{t-1}) + \beta(\eta - \Delta d), & \text{任务执行中} \end{cases} \quad (3)$$

其中: Δd 表示机械臂末端位置与参考路径之间的距离; β 为控制机械臂末端偏离参考路径时受到奖励或惩罚的比例系数; η 为参考路径奖励半径,当机械臂末端在 η 内时会得到奖励,否则会受到惩罚。

在强化学习中,这种奖励机制可以诱导机械臂学习参考路径,使策略更快收敛,提高学习效率。

3 机械臂路径规划算法

SAC是一种基于Actor-Critic无模型强化学习框架,它融合了最大熵思想,在获得高回报的同时,也具有较强的探索能力和较高的鲁棒性^[17]。结合奖励算法和SAC强化学习方法,可以用奖励函数指导智能体学习如何选择最优行为,同时使用SAC训练智能体,使它根据定义的奖励函数和状态选择合适的动作。通过设计合适的奖励函数,智能体可以学习如何选择最优路径,使得机器人准确到达目标点。

综上所述,将奖励算法和SAC强化学习算法结合,可以构建一种新的路径规划算法,使得机器人能够根据环境状态动态地选择最优路径,具有较高的适应性和鲁棒性。

3.1 最大熵策略

SAC强化学习算法可以探索更多情况,以提高学习效率,且避免陷入局部最优解,在获得的最高回报和随机性探索之间寻找一种平衡,使策略可以兼顾预期回报与最大熵。在SAC中,最优策略表示为:

$$\pi^* = \arg \max_{\pi} \sum_{(s_t, a_t) \sim \rho_{\pi}} [R(s_t, a_t) + \alpha H] \quad (4)$$

其中: R 是奖励; H 为熵; $\mathbb{E}$ 表示求奖励和熵的期望; α 是温度系数,决定了熵值相较于奖励的比重,调整 α 可以控制最优策略的探索随机性。 H 的计算式为:

$$H(\pi(\cdot | s_t)) = -\mathbb{E}_{a \sim \pi(\cdot | s_t)} [\log \pi(a | s_t)] \quad (5)$$

熵值的大小反映了策略 $\pi(\cdot | s_t)$ 的随机程度,在熵较大时,机械臂在价值相近的动作中随机选取一个执行。

在SAC算法中,最大熵是策略的目标之一,因此用于表示预期回报的V函数和Q函数中的熵是奖励的一部分,被称为软性状态价值函数(软性V函数)和软性动作价值函数(软性Q函数)^[18],分别表示为:

$$V_{\text{soft}}^{\pi}(s) = \mathbb{E}_{s_t, a_t \sim \rho_{\pi}} \left[\sum_{t=0}^{\infty} \gamma^t (r(s_t, a_t) + \alpha H(\pi(\cdot | s_t))) \middle| s_0 = s \right] \quad (6)$$

$$Q_{\text{soft}}^{\pi}(s, a) = \mathbb{E}_{s_t, a_t \sim \rho_{\pi}} \left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) + \alpha \sum_{t=1}^{\infty} \gamma^t H(\pi(\cdot | s_t)) \middle| s_0 = s, a_0 = a \right] \quad (7)$$

软性Q函数的贝尔曼方程形式表示为:

$$Q_{\text{soft}}^{\pi}(s, a) = \mathbb{E}_{s' \sim \rho(s_t, a), a' \sim \pi} \left[r(s, a) + \gamma (Q_{\text{soft}}^{\pi}(s', a') + \alpha H(\pi(\cdot | s'))) \right] \quad (8)$$

软性Q函数和软性V函数的更新式为:

$$Q_{\text{soft}}^{\pi}(s, a) = \mathbb{E}_{s' \sim \rho(s_t, a)} [r(s, a) + \gamma V_{\text{soft}}^{\pi}(s')] \quad (9)$$

$$V_{\text{soft}}^{\pi}(s) = \mathbb{E}_{a \sim \pi} [Q_{\text{soft}}^{\pi}(s, a) - \alpha \log \pi(a | s)] \quad (10)$$

通过对式(9)~(10)不断迭代,Q函数的输出将逐渐收敛至最优Q值。

3.2 基于能量模型的策略

SAC算法对AC策略的更新方式进行了改进。在SAC算法训练的过程中,策略向着软性Q函数的指数方向更新:

$$\pi(a_t | s_t) \propto \exp \left(\frac{1}{\alpha} Q_{\text{soft}}(s_t, a_t) \right) \quad (11)$$

在强化学习场景下,软性Q函数若是多峰,则代表问题的解不唯一。面对有多个最优解或存在次优解时,基于能量模型的策略分布使算法可对所有可行的解进行学习。当环境发生变化,之前的最优解行不通时,基于能量模型的策略分布可以迅速调整策略得到新的解。对于SAC算法,最优策略的形式如下:

$$\pi_{\text{MaxEnt}}^*(a_t | s_t) = \exp \left(\frac{1}{\alpha} (Q_{\text{soft}}^*(s_t, a_t) - V_{\text{soft}}^*(s_t)) \right) \quad (12)$$

3.3 SAC强化学习算法

本文引入两个结构相同的Q网络同时训练,每次迭代时选择较小的Q值更新策略网络,防止对动作价值估计过高^[19]。Target-Q网络在每次迭代中进行软更新,网络参数的变化较为平缓。使用第2章所述的基于路径模仿的奖励函数,诱导机械臂学习参考路径。

本文算法的框架如图2所示。策略网络将来自环境的状态 s 作为输入,有13个参数,输出动作 a ,共8个参数,隐藏层是5个全连接层,每层512个神经元,使用Leaky ReLU^[20]和Tanh分别作为隐藏层和输出层的激活函数。

设策略网络参数为 φ ,损失函数为:

$$J_{\pi}(\varphi) = \mathbb{E}_{s_t \sim D, a_t \sim \pi_{\varphi}} [\log \pi_{\varphi}(a_t | s_t) - Q_{\theta}(s_t, a_t)] \quad (13)$$

其中: D 表示经验回放池,奖励函数根据任务完成度和机械臂末端与参考路径的距离计算出奖励,并且存到经验回放池,经验回放池将状态、转换后的状态、动作和奖励 $(s_t, a_t, s_{t+1}, R_{t+1})$ 作为Q网络训练的数据来源。 α 为温度参数,随着状态的变化而自动调节,面对探索过的环境状态,应当减小温度参数令熵减小,而面对未知状态应当增大温度参数,增强策略探索的随机性。温度参数 α 自动调节过程可表示为:

$$J(\alpha) = \mathbb{E}_{a_t \sim \pi_{\varphi}} [-\alpha \log \pi(a_t | s_t) - \alpha \bar{H}] \quad (14)$$

其中 $\bar{H}$ 是预设的最小熵。

4个Q网络结构完全相同,它们的输入为状态 s 和策略网络输出的动作 a ,共21个参数,输出单个参数即Q值,隐藏层为3个全连接层,每层512个神经元,使用Leaky ReLU作为激活函数。设Q网络的参数为 θ ,损失函数:

$$J_Q(\theta) = \mathbb{E}_{(s_t, a_t, s_{t+1}) \sim D} \left[\frac{1}{2} (Q_\theta(s_t, a_t) - \hat{Q}_\theta(s_t, a_t))^2 \right] \quad (15)$$

$\hat{Q}_\theta(s_t, a_t)$ 的计算式为:

$$\hat{Q}_\theta(s_t, a_t) = \left(r(s_t, a_t) + \gamma (Q_{\bar{\theta}}(s_{t+1}, a_{t+1}) - \alpha \log(\pi_\varphi(a_{t+1}|s_{t+1}))) \right) \quad (16)$$

设 Target-Q 网络的参数为 $\bar{\theta}$, 每次迭代中对参数软更新, 更新式:

$$\bar{\theta} \leftarrow \tau \theta + (1 - \tau) \bar{\theta} \quad (17)$$

其中: τ 值大于 0 但远小于 1。

SAC 算法的伪代码如下算法 1 所示。

算法 1 SAC 算法。

输入 衰减因子 γ 、经验回放池容量 P 、训练次数 M 、经验回放池采样的 Batch Size 为 K ;

输出 参数为 φ 的最优策略网络。

初始化 策略网络参数 φ 、Q 网络参数 θ_1 和 θ_2 、目标 Q 网络参数

$\bar{\theta}_1$ 和 $\bar{\theta}_2$ 、温度参数 α 。

for $m=0:M$ do:

将状态设置为初始状态 $s = s_0$

for s 不为终止状态 do:

Actor 网络根据机械臂当前状态 s 输出下一步的动作 a 并执行

将状态 s 、动作 a 、奖励 r 和下一个状态 s_t 记录至经验回放池

if 经验回放池样本数量 $> K$ do:

更新 Q 网络参数

$\theta_i \leftarrow \theta_i + \lambda \nabla_{\theta_i} J(\theta_i) (i = 1, 2)$

更新策略网络参数 $\varphi \leftarrow \varphi + \lambda \nabla_{\varphi} J(\theta_i)$

更新温度参数 $\alpha \leftarrow \alpha + \lambda \nabla_{\alpha} J(\alpha)$

更新目标 Q 网络 $\bar{\theta}_i \leftarrow \tau \theta_i + (1 - \tau) \bar{\theta}_i (i = 1, 2)$

else

继续收集样本

end if

end for

end for




图2 本文算法的框架

Fig. 2 Framework of proposed algorithm


4 实验与结果分析

本章通过实验展示本文算法的实际效果,验证该算法在解决实际任务问题中的可行性,通过对比实验验证该算法相较于深度确定性策略梯度 (Deep Deterministic Policy Gradient, DDPG) 强化学习算法^[21]训练速度更快且成功率更高。

4.1 实验环境

强化学习环境基于 Unity ML-Agents 工具包搭建,使用 Python 实现强化学习算法,使用 TensorFlow 构建深度网络。

实验场景如图 3 所示,机械臂放置在桌面上,机械臂前方摆放一个硬币和一个杯子,首先机械臂末端移动到硬币上方,通过电磁铁将硬币拾起,再将硬币置入杯子中。



(a) 机械臂初始状态

(b) 机械臂拾取硬币

图3 机械臂路径规划训练场景

Fig. 3 Training scene of manipulator path planning

4.2 实验结果与分析

为验证本文算法的训练速度和效果,另外设置一组路径模仿算法作为对比。将通过用手拖动机械臂得到的路径作

为参考路径。两种算法如下:

本文算法基于路径模仿和 SAC 算法。奖励函数如第 2 章所述,智能体所受到的奖励和惩罚与是否完成任务以及对参考路径的学习程度有关, SAC 强化学习算法能较好地对环境进行探索,提高学习速度。

基于路径模仿和 DDPG 算法。DDPG 算法与 SAC 算法同属于 Actor-Critic 框架,不同的是 DDPG 算法是直接选取概率最大的动作去执行。DDPG 算法包含 4 个神经网络:策略网络、目标策略网络、Q 网络和目标 Q 网络,这些网络的结构与 SAC 算法中对应网络结构一致。

对上述两种算法各训练 1000 回合,每个训练回合机械臂最多执行 100 次动作,若达到 100 次动作后仍无法完成任务则恢复初始状态,开始下一轮训练。统计两种算法在每个训练回合的累积奖励,绘制相应的曲线如图 4 所示。




图4 两种算法的奖励变化曲线

Fig. 4 Reward change curves for two algorithms

从图4可以看出,两种算法在开始训练时机械臂得到的奖励都比较低,为-30左右。随着训练次数的增加,基于路径模仿和SAC算法的奖励在不断上升,400回合之后奖励值稳定在15左右。基于路径模仿和DDPG算法的奖励增长曲线滞后于本文算法,在训练到200回合之后开始增长,在600回合左右时奖励值稳定在12左右。

每训练40回合统计一次任务成功率,两种算法训练1000回合的任务成功率曲线如图5所示。




图5 两种算法的成功率变化曲线

Fig. 5 Change curves of success rate for two algorithms

从图5可以看出,成功率曲线与奖励曲线的趋势基本一致,两种算法在训练刚开始时成功率都很低,随着训练回合增多,成功率逐渐增高,基于路径模仿和SAC算法在第400回合左右成功率稳定在88%左右,而基于路径模仿和DDPG算法在600回合左右时成功率稳定在88%左右。

机械臂基于两种算法分别规划10条路径,统计两种算法所规划路径的平均长度以及与参考路径的距离差,统计结果如表1所示。

表1 10条路径的路径规划实验结果 单位: cm

Tab. 1 Experimental results of path planning for ten paths

ten paths			
路径规划 算法	路径 平均长度	与参考路径的 最大距离	与参考路径的 平均距离
SAC	42.2	2.1	0.8
DDPG	53.7	3.8	1.9

机械臂基于路径模仿和SAC算法和基于路径模仿和DDPG算法规划的路径与参考路径的对比如图6、7所示。




图6 参考路径及基于路径模仿和SAC算法规划的路径对比

Fig. 6 Comparison between reference path and path based on path imitation and SAC algorithm

为验证基于路径模仿和SAC的算法对不同路径的学习效果,采集一条不同的机械臂运动路径作为参考路径令机械

臂学习,令机械臂规划一条运动路径完成实验任务。基于SAC方法的路径规划算法所规划的路径和参考路径的对比如图8所示,基于SAC方法的路径规划算法规划的路径长度为58.4 cm,偏离参考路径的最大距离为1.8 cm,偏离参考路径的平均距离为0.9 cm,机械臂针对不同的参考路径都能学习并规划合理的路径来完成任务。




图7 参考路径和基于路径模仿和DDPG算法规划的路径对比

Fig. 7 Comparison between reference path and path based on path imitation and DDPG algorithm




图8 不同的参考路径及基于路径模仿和SAC算法规划的路径对比

Fig. 8 Comparison of different reference path and path based on path imitation and SAC algorithm

5 结语

针对目前机械臂强化学习存在奖励稀疏导致的收敛速度慢的问题,本文提出一种基于路径模仿和SAC强化学习的机械臂路径规划算法。首先对基于路径模仿和SAC强化学习的机械臂路径规划算法的基本原理进行描述;其次介绍了基于路径模仿的奖励函数设计原理;接着对SAC强化学习算法进行了介绍,给出了算法流程;最后进行了机械臂路径规划对比实验,实验结果表明本文算法能够有效训练机械臂完成硬币投掷入杯的任务,路径模仿机制解决了强化学习的训练中奖励稀疏难以训练的问题,SAC算法相较于DDPG算法探索能力更强,所规划的路径更加合理。

参考文献 (References)

- [1] YU M, CHEN S, YAO Y, et al. Research on dual-arm coordinated trajectory planning in grid coordinate space [C]// Proceedings of the 2020 IEEE 5th Information Technology and Mechatronics Engineering Conference. Piscataway: IEEE, 2020: 985-989.
- [2] VAREDI-KOULAEI S M, MOKHTARI M. Trajectory tracking solution of a robotic arm based on optimized ANN [C]// Proceedings of the 2018 6th RSI International Conference on Robotics and Mechatronics. Piscataway: IEEE, 2018: 76-81.
- [3] GANDIKOTA R. Computer vision for autonomous vehicles [EB/OL]. [2022-10-18]. <https://arxiv.org/pdf/1812.02542.pdf>.
- [4] SCHWARTING W, ALONSO-MORA J, RUS D. Planning and decision-making for autonomous vehicles [J]. Annual Review of Control, Robotics, and Autonomous Systems, 2018, 1: 187-210.
- [5] LV N, LIU J, JIA Y. Dynamic modeling and control of deformable linear objects for single-arm and dual-arm robot manipulations [J]. IEEE Transactions on Robotics, 2022, 38(4): 2341-2353.
- [6] LI S, JIN L, MIRZA M A. Kinematic Control of Redundant Robot Arms Using Neural Networks [M]. New York: Wiley-IEEE Press, 2019.
- [7] MATHEW M J M R, HIREMATH S S. Reinforcement learning based approach for mobile robot navigation [C]// Proceedings of the 2019 International Conference on Computational Intelligence and Knowledge Economy. Piscataway: IEEE, 2019: 523-526.
- [8] ABDUL HAMEED M S, KHAN M M, SCHWUNG A. Curiosity based RL on robot manufacturing cell [C]// Proceedings of the 2021 22nd IEEE International Conference on Industrial Technology. Piscataway: IEEE, 2021: 1048-1053.
- [9] WANG Z, SCHAUL T, HESSEL M, et al. Dueling network architectures for deep reinforcement learning [C]// Proceedings of the 33rd International Conference on Machine Learning. New York: JMLR.org, 2016: 1995-2003.
- [10] GU S, LILLICRAP T, SUTSKEVER I, et al. Continuous deep Q-learning with model-based acceleration [C]// Proceedings of the 33rd International Conference on Machine Learning. New York: JMLR.org, 2016: 2829-2838.
- [11] PRIANTO E, KIM M S, PARK J-H, et al. Path planning for multi-arm manipulators using deep reinforcement learning: soft actor-critic with hindsight experience replay [J]. Sensors, 2020, 20(20): 5911.
- [12] 张永梅, 赵家瑞, 吴爱燕. 好奇心驱动的深度强化学习机器人路径规划算法[J]. 科学技术与工程, 2022, 22(25): 11075-11083. (ZHANG Y M, ZHAO J R, WU A Y. A robot path planning algorithm based on curiosity-driven deep reinforcement learning [J]. Science Technology and Engineering, 2022, 22(25): 11075-11083.)
- [13] 于建均, 徐聪驰, 阮晓钢, 等. 基于神经网络的机械臂的模仿学习研究[J]. 控制工程, 2017, 24(11): 2368-2373. (YU J J, XU C C, RUAN X G, et al. Research of imitation learning in robot arm based on neural network [J]. Control Engineering of China, 2017, 24(11): 2368-2373.)
- [14] RAHMATIZADEH R, ABOLGHASEMI P, BEHAL A, et al. From virtual demonstration to real-world manipulation using LSTM and MDN [C]// Proceedings of the 32nd AAAI Conference on Artificial Intelligence and 30th Innovative Applications of Artificial Intelligence Conference and 8th AAAI Symposium on Educational Advances in Artificial Intelligence. Menlo Park: AAAI Press, 2018: 6524-6531.
- [15] FINN C, LEVINE S, ABBEEL P. Guided cost learning: deep inverse optimal control via policy optimization [C]// Proceedings of the 33rd International Conference on Machine Learning. New York: JMLR.org, 2016: 49-58.
- [16] 汤自林, 高霄, 肖晓晖. 基于模仿学习的变刚度人机协作搬运控制[J]. 浙江大学学报(工学版), 2021, 55(11): 2091-2099. (TANG Z L, GAO X, XIAO X H. Variable stiffness control for human-robot cooperative transportation based on imitation learning [J]. Journal of Zhejiang University (Engineering Science), 2021, 55(11): 2091-2099.)
- [17] HAARNOJA T, ZHOU A, ABBEEL P, et al. Soft actor-critic: off-policy maximum entropy deep reinforcement learning with a stochastic actor [C]// Proceedings of the 35th International Conference on Machine Learning. New York: JMLR.org, 2018: 1861-1870.
- [18] CHENG Y, SONG Y. Autonomous decision-making generation of UAV based on soft actor-critic algorithm [C]// Proceedings of the 2020 39th Chinese Control Conference. Piscataway: IEEE, 2020: 7350-7355.
- [19] 陈松, 章晓芳, 章宗长, 等. 基于线性动态跳帧的深度双Q网络[J]. 计算机学报, 2019, 42(11): 2561-2573. (CHEN S, ZHANG X F, ZHANG Z Z, et al. Deep double Q-network based on linear dynamic frame skip [J]. Chinese Journal of Computers, 2019, 42(11): 2561-2573.)
- [20] HU H. VReLU activation functions for artificial neural networks [C]// Proceedings of the 2018 14th International Conference on Natural Computation, Fuzzy Systems and Knowledge Discovery. Piscataway: IEEE, 2018: 856-860.
- [21] LILLICRAP T P, HUNT J J, PRITZEL A, et al. Continuous control with deep reinforcement learning [EB/OL]. [2022-10-18]. <https://arxiv.org/pdf/1509.02971.pdf>.

This work is partially supported by National Key Research and Development Program of China (2018YFB1703003), Shaanxi Provincial Key Research and Development Program (2022SF-353), Xi'an Science and Technology Plan Program (2022JH-RYFW-0072).

SONG Ziyang, born in 1998, M. S. candidate. His research interests include internet of things, behavior recognition.

LI Junhuai, born in 1969, Ph. D., professor. His research interests include internet of things, behavior recognition, network computing.

WANG Huaijun, born in 1981, Ph. D., associate professor. His research interests include intelligent perception, behavior recognition, intelligent manufacturing.

SU Xin, born in 1994, M. S. candidate. His research interests include internet of things.

YU Lei, born in 1976, M. S., lecturer. Her research interests include internet of things, computer networks.