

分类号：_____

学校代码： 10153

UDC：_____

密 级：_____

沈阳建筑大学

硕士学位论文

基于神经网络的空间机械臂跟踪控制研究

Research on tracking control of space manipulator based
on neural network

作 者 姓 名： _____ 张家豪

学 号： _____ 2225541076

指 导 教 师： _____ 王 娟

专业学位名称： _____ 电子信息

入 学 年 月： _____ 2022 年 9 月

答辩日期： 2025 年 6 月 11 日 答辩委员会主席： 吴东升

摘要

空间机械臂作为航天器在轨服务与空间站维护的核心执行机构,凭借其高自由度运动特性和低能耗优势,已成为空间操作装备领域的重要研究方向。空间机械臂系统因其固有的高阶非线性动力学特性、多自由度、强耦合等特性,以及在实际任务中出现的输入非线性与未知外部干扰等问题,给其轨迹跟踪控制带来了挑战。在环境未知与外部扰动下,确保空间机械臂能够稳定的跟踪期望轨迹,具有实际意义和应用价值。本文聚焦于未知有界扰动与模型不确定性共存条件下空间机械臂的鲁棒轨迹跟踪控制问题,提出了两种控制方案,以提高其在未知环境和干扰下的轨迹跟踪精度与抗干扰能力,最终使空间机械臂取得良好的轨迹跟踪控制效果。本文研究的主要内容如下:

(1) 在考虑外部扰动的情况下基于拉格朗日方法建立了二连杆刚性空间机械臂的动力学方程,并介绍了 RBF 神经网络控制、模糊神经网络控制和模型预测控制的理论知识,为后续工作建立基础。

(2) 在空间机械臂动力学方程的基础上,针对存在输入死区且受外部干扰的空间机械臂轨迹跟踪问题,提出了一种基于模糊 RBF 神经网络的控制算法。该算法分为两部分,其一是使用模糊神经网络逼近空间机械臂系统模型的不确定项与未知干扰,其二是采用模糊神经网络逼近并补偿输入死区。最后对空间机械臂进行仿真实验,实验结果验证了所设计控制器的有效性。

(3) 在空间机械臂的动力学方程基础上,针对具有输入输出约束的空间机械臂轨迹跟踪控制,提出了一种基于 RBF 神经网络优化的模型预测控制算法。首先通过模型预测控制将空间机械臂的轨迹跟踪控制转化为动态优化问题;其次在经典的模型预测控制基础上,采用 RBF 神经网络逼近和最小化模型预测控制的代价函数来优化空间机械臂的控制输入;最后对空间机械臂进行仿真实验,验证了所设计的控制器的有效性。

关键词: 空间机械臂; RBF 神经网络; 模糊神经网络; 模型预测控制; 轨迹跟踪控制

Abstract

As the core actuator of spacecraft in-orbit service and space station maintenance, space manipulator has become an important research direction in the field of space operation equipment due to its high degree of freedom motion characteristics and low energy consumption advantages. Because of its inherent high order nonlinear dynamics, multiple degrees of freedom, strong coupling, input nonlinearity and unknown external interference in practical tasks, space manipulator system brings challenges to its trajectory tracking control. In the case of unknown environment and external disturbance, it is of practical significance and application value to make the space manipulator track the desired trajectory stably. This thesis focuses on the robust trajectory tracking control problem of the space manipulator under the coexistence of unknown bounded disturbance and model uncertainty. Two control schemes are proposed to improve the trajectory tracking accuracy and anti-interference ability of the space manipulator under unknown environment and interference, and finally make the space manipulator achieve good trajectory tracking control effect. The main contents of this thesis are as follows:

(1) The dynamic equation of the two-link rigid space manipulator is established based on Lagrange method considering external disturbance, and the theoretical knowledge of RBF neural network control, fuzzy neural network control and model predictive control is introduced, which lays a foundation for subsequent work.

(2) Based on the dynamic equation of the space manipulator, a control algorithm based on fuzzy RBF neural network is proposed to solve the trajectory tracking problem of the space manipulator with input dead zone and external interference. The algorithm is divided into two parts: one is to use fuzzy neural network to approximate the uncertainties and unknown disturbances of the space manipulator system model; the other is to use fuzzy neural network to approximate and compensate the input dead zone. Finally, the simulation experiment of the space manipulator is carried out, and the experimental results verify the effectiveness of the designed controller.

(3) Based on the dynamic equation of the space manipulator, a model predictive control algorithm based on RBF neural network is proposed for the trajectory tracking control of the space manipulator with input and output constraints. Firstly, the trajectory tracking control of space manipulator is transformed into a dynamic optimization problem by model predictive control. Secondly, on the basis of classical model predictive control, RBF neural network is used to approximate and minimize the cost function of model predictive control to optimize the control input of space manipulator. Finally, the simulation experiment of the space manipulator is carried out to verify the effectiveness of the designed controller.

Keywords: space manipulator; RBF neural network; fuzzy neural network; model predictive control; trajectory tracking control.

目 录

1 绪论.....	1
1.1 研究背景与意义.....	1
1.2 空间机械臂国内外发展现状	2
1.3 机械臂轨迹跟踪控制研究现状	5
1.4 本文主要研究内容.....	8
2 空间机械臂建模及其控制理论基础	11
2.1 空间机械臂建模.....	11
2.2 神经网络控制理论.....	14
2.3 模糊神经网络控制理论.....	17
2.4 模型预测控制理论.....	19
2.5 本章小结.....	21
3 空间机械臂的模糊神经网络控制	23
3.1 引言.....	23
3.2 问题描述.....	23
3.3 针对建模误差的模糊神经网络控制器设计	25
3.4 针对输入死区的模糊神经网络补偿控制	27
3.5 模糊 RBF 神经网络控制稳定性分析	28
3.6 仿真实验.....	29
3.7 本章小结.....	33
4 空间机械臂的神经网络模型预测跟踪控制	35
4.1 引言.....	35
4.2 问题描述.....	35
4.3 空间机械臂的模型预测控制	36
4.4 基于 RBF 神经网络优化的模型预测控制	39
4.5 RBF 模型预测控制稳定性分析	40
4.6 仿真实验.....	41
4.7 本章小结.....	45
5 结论和展望.....	47
5.1 结论.....	47
5.2 创新点.....	47
5.3 展望.....	48
参考文献.....	49

图目录

图 1.1 服务机器人.....	1
图 1.2 焊造机器人.....	1
图 1.3 物流机器人.....	2
图 1.4 医疗机器人.....	2
图 1.5 Canadarm 机械臂	3
图 1.6 ESA 机器人	3
图 1.7 天宫空间站机械臂 I	4
图 1.8 天宫空间站机械臂 II	4
图 1.9 本文结构框架.....	9
图 2.1 双连杆机械臂结构图.....	12
图 2.2 RBF 神经网络结构图	15
图 2.3 模糊神经网络结构图.....	18
图 3.1 输入死区数学模型.....	23
图 3.2 模糊神经网络控制器.....	24
图 3.3 符号函数.....	26
图 3.4 模糊 RBF 神经网络仿真模型	30
图 3.5 空间机械臂 3D 仿真.....	30
图 3.6 空间机械臂的位置跟踪.....	31
图 3.7 空间机械臂的速度跟踪.....	31
图 3.8 空间机械臂死区及其估计	32
图 3.9 空间机械臂的输入力矩.....	33
图 4.1 空间机械臂仿真模型.....	41
图 4.2 RBF 模型预测控制位置跟踪	42
图 4.3 空间机械臂的轨迹跟踪误差.....	43
图 4.4 RBF 模型预测控制位置跟踪	44
图 4.5 代价函数 J 变化图	44
图 4.6 空间机械臂的控制力矩.....	45

1 绪论

1.1 研究背景与意义

机械臂作为典型的仿生执行机构，通过多自由度运动学构型复现人类手臂功能，已成为智能制造体系的核心装备。该自动化装置融合精密机械设计、伺服驱动技术及智能控制算法，能够依据预设程序或实时指令完成物料搬运、精密装配以及高危环境作业等任务，显著增强了生产力，不仅使人们得以从繁琐的重复性工作中解脱，更推动了社会生产效率，机械臂技术发展水平直接反映国家先进制造能力。作为多学科交叉融合的产物，机械臂技术涉及材料科学，如碳纤维复合材料关节设计、信息物理系统、CPS 架构实时控制、人工智能等前沿领域，并形成涵盖运动学建模、路径轨迹规划以及力位混合控制的理论体系。

在高新产业驱动下机械臂技术呈现显著进化特征——从早期简单码垛发展到现今可完成微电子芯片贴装等精密操作，机械臂的应用场景也已突破传统制造业壁垒，在太空维护^[1]、深海探测^[2]、微创手术^[3]及智能仓储^[4]等领域得到了广泛的应用。各类机器人如图 1.1-1.4 所示。机器人技术已成为全球科技竞争的关键战略支点，各国通过政策引导、技术攻关和产业协同构建创新生态，机器人技术在未来将重塑全球制造业格局，催生出许多新兴产业，成为推动第四次工业革命的核心驱动力。全球主要工业国家均已将机器人技术列为战略重点：美国通过《国家机器人计划》整合多机构资源推进基础研究，分别由 NSF 主导基础研究、NASA 开发太空机器人、USDA 推进农业自动化、NIH 研发医疗机器人；日本也制定《机器人新战略》着力保持机器人技术的领先地位；我国在《中国制造 2025》明确将智能机器人技术作为产业升级突破口，“十四五”规划中更强调了智能机器人重点专项。



图1.1 服务机器人
Fig. 1.1 Service robot



图1.2 焊造机器人
Fig. 1.2 Welding robot




图1.3 物流机器人

Fig. 1.3 Logistics robot



图1.4 医疗机器人

Fig. 1.4 Medical robot

随着人类对太空探索与利用的深入，空间机械臂已成为在轨服务、空间站维护及深空探测任务中不可或缺的核心装备。空间机械臂作为在轨服务的关键装备，凭借其冗余自由度构型与多模态作业能力，逐渐成为深空探测任务的核心技术载体。由于太空环境存在极端温度波动、高能粒子辐射及微陨石撞击等多重风险，传统宇航员舱外活动面临着巨大的风险与任务失败率以及高昂的操作成本。通过部署空间机械臂系统，不仅可以降低空间作业任务风险系数，更能实现高精度的在轨操作，显著提升任务成功率。以国际空间站的 Canadarm2 机械臂为例，累计完成了超过 100 次的航天器捕获与舱段组装任务，并且将精度误差控制在 1.5 mm 以内；中国“天和”核心舱机械臂更实现了七自由度运动并且具备舱体表面自主爬行功能，支撑了天宫空间站复杂结构的在轨建造。

1.2 空间机械臂国内外发展现状

空间机械臂的发展历史可以追溯至 20 世纪中叶，其发展历程与人类对太空探索的需求密切相关，经历了从概念设计到实际应用，从单一功能到复杂操作，从地面遥控到自主控制的演变，是航天技术与机器人技术结合的产物。空间机械臂的发展从辅助工具演变为空间任务的核心装备，其技术跨越了材料科学、控制工程、人工智能等多个领域。随着航天技术和深空探测的推进，空间机械臂将在太空资源开发、星际探索^[5]中发挥更关键的作用。

自 1961 年苏联航天员加加林完成人类首次载人航天任务以来，人类正式开始进入太空探索，科学家开始探索如何在微重力环境中进行复杂操作。面对传统宇航员的舱外活动存在风险高、效率低等问题，机械臂被国际航天工程界视为提升舱外作业效能的重要技术路径。1967 年，NASA 开始研究 Remote Manipulator System, RMS 即“遥控机械臂”概念，目标是为航天飞机设计辅助工具。1973 年，加拿大 Spar Aerospace 公司受邀参与设计，最终开发出航天飞机机械臂的原型，即后来的 Canadarm。1971~1986 年苏联尝试在礼炮号空间站上试验了简单的机械装置，但功能有限，主要用于固定设备。

航天飞机的投入使用推动了机械臂的实际部署,空间站建设需求进一步催生技术发展。加拿大研制的航天飞机遥控机械臂系统 Canadarm 长 15.2 米,6 自由度,负载能力达 30 吨,于 1981 年随哥伦比亚号航空飞机首飞,主要用于部署和回收卫星^[6],支持哈勃望远镜维修任务,如 1993 年的奋进号第五次 STS-61 任务。欧洲空间局于上世纪 90 年代开发了欧洲机械臂,但受限于国际空间站建设进度,直至 2021 年才部署。日本为国际空间站的“希望号”实验舱开发了小型机械臂 JEM Remote Manipulator System,用于舱外实验设备的操作。国际空间站的全面运营成为空间机械臂发展的核心平台,多国协作推动技术多样化。2001 年加拿大为 ISS 设计的第二代机械臂 Canadarm2,长 17.6 米,7 自由度,具备自主移动能力,可在空间站表面“爬行”,参与超过 100 次任务,包括组装 ISS 模块、捕获货运飞船。2021 年随俄罗斯“科学号”实验舱升空的欧洲臂 ERA,是首个可在国际空间站俄罗斯舱段操作的机械臂,具备完全自主操作能力^[7]。

深空探测需求(如月球、火星基地)推动空间机械臂向智能化、多功能化发展。2021 年部署的中国空间站机械臂:中国天和核心舱配置的多关节冗余自由度空间机械臂,具备 10 米级作业半径与 25 吨级负载能力,其自主舱表转移功能与舱外载荷精准部署性能,主要依托机器视觉环境感知网络与末端执行机构自适应抓取控制算法实现;NASA 研制的人形机器人技术体系,自 2011 年 Robonaut2 成为首个国际空间站人机协同作业验证平台后,其 Valkyrie 地外探索机器人通过仿生双臂协同操作系统,已形成面向月球/火星极端环境的模块化任务执行能力。



图1.5 Canadarm机械臂

Fig. 1.5 Canadarm robotic manipulator



图1.6 ESA机器人

Fig. 1.6 ESA robot

中国空间机械臂的发展历程是近年来中国航天技术快速崛起的缩影,体现了从技术跟踪到自主创新、从地面试验到空间应用的跨越式进步。其研发历程紧密围绕国家载人航天工程和深空探测任务展开,例如天宫空间站建设、探月工程,形成了具有自主知识产权的核心技术体系。

中国载人航天工程于 1992 年正式启动,在工程初期技术研发重点集中于神舟系列载人飞船系统集成与空间交会对接技术体系构建,此时空间机械臂尚未纳入核心载荷发

展规划,机械臂尚未成为重点。随着国际空间站机械臂的成功应用,国内航天工程界逐渐认识到空间机械臂在航天器维护、载荷操作等任务中的战略价值,由此启动相关技术储备工作。21 世纪初,国内科研机构包括哈尔滨工业大学、北京航空航天大学等率先开展了空间机械臂多体系统动力学建模、非完整约束条件下轨迹规划算法、基于视觉的柔顺控制等关键理论研究,重点突破微重力环境下的刚柔耦合动力学特性分析与高精度运动控制等基础科学问题。同步开展的还有国防科技工业部门组织的专项预研计划,着重攻克空间机械臂高功率密度关节驱动技术、复合材料轻量化构型设计、极端热环境适应性等工程化关键技术。工程验证阶段始于 2006 年,中国航天科技集团五院成功研制出国内首套全功能六自由度空间机械臂地面验证系统。该原型系统通过模块化关节单元设计实现了系统可重构性,采用基于力位混合控制的遥操作技术方案,有效验证了多自由度协同运动控制、末端定位精度补偿等核心功能,为后续天和核心舱机械臂的工程实施奠定了技术基础。

2011 年发射的天宫一号目标飞行器和 2016 年发射的天宫二号空间实验室,推动机械臂技术从理论走向工程化。天宫二号搭载了国内首个空间机械臂实验装置,长度约 3 米,具备抓取、搬运和精细操作能力。通过航天员遥控操作,成功完成舱外设备模拟安装与维护任务,验证了机械臂在轨操作可行性。天宫空间站的核心需求推动了机械臂技术的全面工程化,中国空间机械臂正式进入实用阶段^[8]。中国空间站机械臂系统核心功能如下:舱段转位:协助问天、梦天实验舱与核心舱的对接与位置调整。设备维护:搬运舱外载荷、辅助航天员出舱活动,如 2021 年神舟十二号任务中,机械臂将航天员聂海胜精准送至作业点。状态监测:通过视觉系统对空间站外表面进行巡检,检测微陨石撞击或设备异常。中国空间机械臂的标志性成果——天和核心舱机械臂,长度 10 米,最大负载 25 吨,七自由度,可模拟人类手臂的灵活性,末端移动速度达 0.6 米/秒。采用“自主爬行”技术,通过末端执行器与舱体表面适配器的交替抓握,实现在空间站表面类似加拿大机械臂 Canadarm2 的“蠕虫运动”的自由移动。



图1.7 天宫空间站机械臂 I

Fig. 1.7 Tiangong Space Station manipulator I




图1.8 天宫空间站机械臂 II

Fig. 1.8 Tiangong Space Station manipulator II

中国空间机械臂的发展从技术跟随到技术并行创新, 仅用 20 余年便跻身世界先进水平。未来, 随着天宫空间站的长期运营和深空探测任务的推进, 中国空间机械臂将在太空资源开发、星际基地建设等领域发挥更核心的作用, 成为国家太空战略能力的重要支柱。

1.3 机械臂轨迹跟踪控制研究现状

机械臂系统是一个复杂的高阶非线性、多输入多输出且强耦合的时变系统。随着工业的发展, 机械臂的应用范围不断扩大, 与此同时对机械臂也提出更高的要求。然而, 太空极端环境下的动力学不确定性、资源受限性与任务复杂性, 使得机械臂高精度轨迹跟踪控制面临严峻挑战, 相关研究成为航天机器人领域的前沿热点。学者们不断地在研究机械臂系统的工作理论与控制技术, 以便能更好地操纵机械臂来完成工作任务。目前在机械臂控制领域已经产生许多的研究成果, 而其中对机械臂系统的轨迹跟踪控制研究是必要的。械臂控制理论经历了从单模态到多模态协同的演进, 早期研究聚焦于经典线性控制策略, 包括 PID 控制^[9-12]、滑模控制^[13-16]等; 近年来随着智能算法的发展, 逐步形成以神经网络动态补偿^[17-21]、模糊逻辑自适应调节^[22-26]为代表的现代智能控制体系。

(1) PID 控制: PID 控制作为一种经典控制方法, 在机械臂控制领域具有重要应用价值。该控制策略基于闭环反馈架构, 通过构建误差动态补偿机制实现精准调节。具体而言, 系统建立实时反馈通道持续监测被控变量与期望值的偏差量, 继而采用时域微分-积分混合算子对误差信号进行多模态处理, 具有结构简洁、参数物理意义明确、鲁棒性强等特点。由于无需建立精确动力学模型即可实现有效控制, PID 算法在工业机械臂领域得到广泛应用。研究表明, 其控制性能主要取决于三个增益参数的整定质量, 这使得参数调整过程具有明确的工程指导性。文献[9]针对机器人机械臂的轨迹控制研究, 提出一种结合 BP 神经网络的改进 PID 的控制系统; 文献[10]采用 MATLAB 联合 Python 搭建了一个六轴机械臂, 引入多智能体思想, 使用强化学习中近端优化算法对传统 PID 控制算法进行改进, 实现多智能体自适应调整参数的新型多智能体自适应 PID 算法; 文献[11]针对现有 PID 方法难以适用于机械臂变有效载荷工况下的控制问题, 基于离散域中时延控制与 PID 控制之间的等价性, 设计了一种自适应 PID 控制律, 提出了一种考虑变有效载荷的机械臂自适应 PID 控制策略; 文献[12]通过建立包含关节柔性效应的空间机械臂动力学模型, 提出一种基于奇异摄动理论与模糊参数自整定的混合控制架构, 解决了柔性关节空间机械臂在多重力环境下的高精度轨迹跟踪问题。尽管如此, PID 控制在机械臂应用中的局限性也不容忽视, 传统 PID 控制仅适用于中低速、精度要求适中的作业场景。此外, 多自由度机械臂的强耦合特性会显著放大参数间的交互影响, 进一步增加了多变量系统的协同优化难度。

(2) 滑模控制: 滑模控制在机械臂运动控制领域展现出独特的理论优势与实用价

值,其核心特征体现在强鲁棒性与建模宽容度两个方面。该控制方法通过设计特定滑动模态,使系统状态在有限时间内收敛至预设滑模面,不仅实现了轨迹跟踪的快速响应特性与无超调稳态性能,更具备计算资源占用率低的工程适用性。相较于传统模型依赖型控制策略,滑模控制仅需掌握系统参数的边界条件,即可构建有效的控制律,这一特性特别适用于具有强非线性耦合特性的多自由度机械臂系统。文献[13]针对机械臂在滑模控制过程中存在的精度较低等问题,利用自适应 RBF 神经网络与设计好的线性滑模面相结合,提出了一种基于自适应参数调节趋近律的机械臂神经网络滑模控制方法;文献[14]结合非奇异终端滑模控制和反正切函数特性,设计了一种反正切非奇异终端滑模控制器,实现了水下机械臂的末端轨迹跟踪控制。

(3) 神经网络控制:神经网络控制技术凭借其强大的非线性映射能力和自学习特性,在复杂系统控制领域展现出显著的优势。相较于传统依赖精确数学模型的控制器,神经网络通过分布式并行计算架构与权值在线更新机制,能够有效处理系统动态不确定性以及外部环境扰动问题。在机械臂控制领域,该技术主要体现两大核心优势:其一,网络经离线训练获得先验知识后,仍可通过在线学习持续优化控制策略,这种动态适应能力显著提升了系统应对时变工况的鲁棒性;其二,网络隐含层对高维特征的非线性提取能力,使得控制器设计无需依赖精确动力学模型即可实现复杂轨迹的跟踪。文献[17]提出一种采用具有权重自适应更新的径向基神经网络辨识的柔性机械臂抑振控制策略,通过减弱机械臂转角波动的方式间接抑制振动;解决了柔性机械臂在运动过程中受到柔性因素的影响会出现剧烈振动的问题;文献[18]考虑系统输出受限和机械系统动力学模型未知,利用径向基函数神经网络设计自适应神经网络控制器,提出了一种基于积分障碍李雅普诺夫函数的自适应神经网络导纳控制方法,实现了约束范围内的轨迹跟踪控制;文献[19]建立了考虑二维变形和扰动转矩的柔性空间机械臂的动力学模型,利用 RBF 神经网络对柔性空间机械臂中的时变项和扰动转矩进行识别和补偿提出了滑模控制策略,有效地减少了扰动转矩对柔性空间机械臂的影响、提高跟踪控制的准确性。最后,通过这些调整神经网络权重自适应律的系数研究成果表明,通过合理设计网络结构与学习机制,神经网络控制能够有效突破传统方法在建模精度与实时性方面的双重约束。

(4) 模糊控制:基于模糊集合理论的智能控制方法在机械臂系统中展现出独特的应用价值,其核心特征在于通过模糊逻辑推理机制实现非线性映射与专家经验的有效融合。模糊控制策略无需依赖精确动力学模型即可建立输入输出间的非线性关系,凭借其强鲁棒性和参数自适应能力,特别适用于处理多自由度机械臂的强耦合、非线性及参数耦合等复杂控制问题。当前研究主要围绕两种范式展开:直接模糊控制通过构建完备的模糊规则库直接生成控制量,而间接模糊控制则通常与经典控制理论相结合形成复合控制架构。文献[22]在考虑存在外界时变干扰与参数不确定的情况下,提出基于模糊补偿的预定时间姿态控制方法,使机械臂系统在预设时间内到达稳定状态;文献[23]针对空

间机械臂系统提出模糊滑模复合控制策略,通过模糊推理动态调节补偿增益,在保证控制精度的同时有效抑制抖振现象;文献[24]针对柔性关节机械手的轨迹跟踪问题,通过融合直接自适应机制与模糊逻辑系统提出基于平滑函数的固定时间自适应模糊控制策略。

尽管近年来在空间机械臂轨迹控制领域取得了许多成果,然而关于输入死区等问题仍然没有得到很好的解决。输入死区在机械系统中广泛存在,由动作器的间隙、滞回、摩擦等缺陷引起,特别是在对控制精度要求很高的情况下严重影响系统的性能,死区非线性除了造成输出误差外,严重时还会对系统造成极限环振荡。文献[27]为了使系统在给定的收敛时间内保持稳定,利用时间尺度变换方法和 Lyapunov 稳定性理论提出了一种新的规定时间自适应神经跟踪控制器,解决了一类具有系统不确定性和死区输入的机器人机械手的规定时间控制问题。文献[28]提出了一种基于神经网络的空间柔性机械臂输入死区模糊补偿方法,用于死区在线实时估计和补偿,解决了关节死区引起的跟踪误差。文献[29]基于自适应反步技术,提出自适应模糊控制方案来解决具有未知死区输出和不可测量状态的非线性反馈系统的跟踪问题。文献[30]考虑柔性臂系统分布参数的特点,采用偏微分方程和边界条件描述柔性机械臂系统的动力学模型,研究了具有死区非线性和输入信号量化的柔性机械臂系统的边界控制问题。现有文献中针对空间机械臂的控制方法中,在考虑系统模型不确定性的同时对关节输入死区进行研究的还很少,因此亟待对其进行深入探索。

对于空间机械臂系统而言, 由于机械臂关节之间的强耦合性, 且易受到外部干扰, 这些问题使得空间机械臂系统的轨迹跟踪控制成为一项具有复杂性和挑战性的任务。在过去的数年间, 迭代控制、切换控制、滑模控制、神经网络等控制算法被广泛地应用于机械臂的轨迹跟踪控制。RBF 神经网络具有一定的容错能力和较强的学习能力, 可以有效地解决非线性问题, 近年来得到广泛的应用。文献[31]针对输入饱和且受未知非线性扰动的柔性机械臂系统, 提出了一种基于非线性扰动观测器的模糊神经网络近似器来实现机械臂控制; 文献[32]设计了基于 RBFNN 补偿的控制方法, 能够实现机械臂在未知特性负载作用下快速准确地跟踪期望轨迹。在机器人运动控制中, 模型预测控制可以处理机器人的动力学约束, 计算出最优的关节运动轨迹, 确保机器人能够准确、稳定地完成轨迹控制任务。文献[33]提出了一种基于鲁棒非线性模型预测控制方法, 在克服模型不确定性和地面机械干扰的同时, 最小化轨迹跟踪误差; 文献[34]采用模型预测控制根据动态环境和各种任务约束来调整机械臂的运动计划。近年来一些学者也开始将模型预测控制与神经网络相结合来获取更为优秀的机械臂控制策略, 传统 MPC 在非线性系统中需反复求解非线性优化问题, 计算负担大; RBF 神经网络通过逼近代价函数可简化优化过程, 提高实时性。文献[35]在机械臂控制中利用阿基米德优化算法解决模型预测控制的优化问题来获得最优控制; 文献[36]将自适应神经网络用于模型预测控制, 通过考

虑具有不同权重和激活函数的 Actor-Critic 方案,设计了自适应学习策略来实现机械臂的轨迹跟踪控制。

伴随全球空间基础设施建设的战略推进,空间机械臂动力学建模与先进控制方法研究已成为航天器在轨服务技术领域的科研焦点。随着我国天宫空间站常态化运营和深空探测计划的推进,空间机械臂作为在轨服务的关键执行机构,其控制性能直接关系到舱段转位、载荷安装等核心任务的成功实施。在复杂的空间环境下,机械臂可能会面对输入非线性以及受到外部未知环境的干扰,导致传统控制策略面临严峻挑战。目前针对输入死区与输入输出约束的空间机械臂研究较少,基于上述情况,本文主要基于神经网络研究了针对输入非线性的空间机械臂的轨迹跟踪控制,着力解决空间机械臂在约束条件下的轨迹跟踪控制难题。

1.4 本文主要研究内容

本文针对空间机械臂的轨迹跟踪控制问题进行了分析研究。主要研究了由于输入死区和输入输出约束给空间机械臂的控制系统带来的问题,本文的具体内容与结构安排如下:

第一章:阐述了空间机械臂技术的应用背景与工程价值,梳理了国内外在空间机械臂领域的技术发展动态,重点分析了轨迹跟踪控制方向的关键技术研究现状,进一步阐述了本文的研究意义。

第二章:本章节主要针对空间机械臂采用拉格朗日法建立了双连杆机械臂的动力学模型以及本文所需的部分基础理论内容,以便于后续章节的控制器设计和稳定性分析,同时介绍了机械臂的特性。

第三章:本章节主要研究了空间机械臂在输入死区下的轨迹跟踪控制。针对空间机械臂所存在的模型误差和机构输入死区问题,提出了一种新的自适应模糊 RBF 神经网络控制方案,用于实现空间机械臂系统的轨迹跟踪控制,运用李雅普诺夫函数方法分析了所设计控制方法的稳定性,最后进行 MATLAB 仿真实验,仿真实验结果证明了该方法可以对空间机械臂的期望轨迹控制进行精确的跟踪。

第四章:本章节针对空间机械臂系统存在的模型误差和输入输出约束问题,提出了一种新的基于自适应 RBF 神经网络优化的模型预测控制算法,通过 RBF 神经网络实时逼近和最小化模型预测控制的代价函数来优化空间机械臂的轨迹跟踪控制,运用李雅普诺夫函数方法分析了所设计控制方法的稳定性,最后进行 MATLAB 仿真实验,仿真实验结果证明了该方法可以实现空间机械臂期望轨迹控制进行精确的跟踪。

第五章:对本文的工作进行了总结与对未来的展望,针对本文现有工作进行总结,对文章存在的不足之处展望了未来的研究方向。

全文的结构如图如 1.9 所示。




图1.9 本文结构框架

Fig. 1.9 Schema of this paper

2 空间机械臂建模及其控制理论基础

2.1 空间机械臂建模

建模是在空间机械臂系统的控制研究中的首要步骤，机械臂的动力学模型以微分方程的形式描述了机械臂的动力学运动方程。在设计控制器时需要一个准确的模型来提供被控对象的详细信息，因此构建精确的动力学模型对于深入研究机械臂的轨迹控制至关重要。机械臂动力学建模的方法包括但不限于：牛顿力学方法^[37]、凯恩法^[38]、拉格朗日方法^[39]。牛顿力学方法通过对机械臂每个关节进行分析，将机械臂分解为多个刚体，对每个连杆进行力与力矩的平衡分析，考虑惯性力、重力、关节驱动力及相邻连杆的相互作用，全面考虑了各个关节的线性运动和角运动；凯恩法结合牛顿法和虚功原理，通过广义速率和偏速度消除约束力，直接建立动力学方程，利用虚功率平衡，将系统动力学分解为主动力与惯性力的平衡；而拉格朗日方法则从能量的角度出发将机械臂视为一个整体，有效避免了机械臂内力项的出现，此外，拉格朗日法引入广义坐标概念，通过广义坐标描述系统，避免直接处理内部约束力，极大地简化了建模过程，适合理论分析和控制器设计。

由于本文的研究内容是主要针对关节角度和关节输入力矩来实现空间机械臂的轨迹跟踪控制，因此本章节根据拉格朗日法建立了空间机械臂的动力学模型。此外，本章节还将阐述机械臂特性、RBF 神经网络控制、模糊神经网络、模型预测控制等理论基础，这些内容为后续章节的控制器设计和系统稳定性分析提供了理论基础。

基于能量守恒定律的拉格朗日力学理论，为构建空间机械臂动态模型提供了成熟的建模手段。拉格朗日方法基于能量的原理，可以有效地描述多自由度机械系统的动力学行为。

拉格朗日方程是一种基于广义坐标的动力学方程，其形式为：

$$L = K - P \quad (2.1)$$

其中， L 是拉格朗日量，即空间机械臂系统动能 K 与势能 P 的差； K 是系统的动能； P 是系统的势能。

拉格朗日方程的基本形式是：

$$\frac{d}{dt} \left(\frac{\partial L}{\partial \dot{q}_i} \right) - \left(\frac{\partial L}{\partial q_i} \right) = \tau_i \quad (2.2)$$

其中 q_i 表示为机械臂第 i 个关节的角度； $\dot{q}_i$ 是关节角度的时间导数，表示关节的角速度； τ_i 是机械臂第 i 个关节的控制力矩或外部施加的力矩。

拉格朗日动力学方法通过系统动能与势能的标量函数，在广义坐标下构建运动微分方程，规避了传统矢量力学中复杂的受力分析过程，适用于复杂的多自由度系统，以一

个双连杆刚性机械臂为例进行动力学建模，其结构如图 2.1 所示：




图2.1 双连杆机械臂结构图

Fig. 2.1 Structure of two link robot manipulator

在图 2.1 中，连杆 1 的质量为 m_1 ，连杆 2 的质量为 m_2 ，连杆 1 的长度为 l_1 ，连杆 2 的长度 l_2 ，连杆 1 与水平方向的角度差为 q_1 ，连杆 2 与连杆 1 之间的角度差为 q_2 。

在空间在轨任务环境下，空间机械臂系统处于微重力准静态工况，其微重力加速度量级满足动力学建模中的重力场弱化假设条件。基于此，可将该系统的动力学特性简化为无重力约束下的自由运动多体系统。针对图 2.1 所示的双自由度空间机械臂构型，本文采用拉格朗日方程建立其刚柔耦合动力学模型。具体推导过程严格遵循能量守恒原理：首先定义广义坐标系下的动能势能函数，继而构建系统拉格朗日算子，最终通过变分原理导出包含惯性矩阵、科里奥利力项及离心力项的非线性微分方程组，下面是具体的建模过程：

首先分别计算两个连杆的动能和势能：

关节 1 动能：

$$K_1 = \frac{1}{2} m_1 l_1^2 \dot{q}_1^2 \quad (2.3)$$

关节 1 势能：

$$P_1 = 0 \quad (2.4)$$

关节 2 动能：

$$K_2 = \frac{1}{2} m_2 l_1^2 \dot{q}_1^2 + \frac{1}{2} m_1 l_1^2 (\dot{q}_1^2 + \dot{q}_2^2) + m_2 l_1 l_2 (\dot{q}_1^2 + \dot{q}_1^2 \dot{q}_2^2) \cos(q_2) \quad (2.5)$$

关节 2 势能：

$$P_2 = 0 \quad (2.6)$$

然后由式(2.1)、式(2.3)、式(2.4)、式(2.5)、式(2.6)联立得到二连杆空间机械臂的拉格朗日函数表达式为:

$$\begin{aligned} L &= K_1 + K_2 - P_1 - P_2 \\ &= \frac{1}{2}(m_1 + m_2)l_1^2\dot{q}_1^2 + \frac{1}{2}m_1l_1^2(\dot{q}_1^2 + \dot{q}_2^2) + m_2l_1l_2(\dot{q}_1^2 + \dot{q}_1\dot{q}_2)\cos(q_2) \end{aligned} \quad (2.7)$$

最后假设空间机械臂不受摩擦力项和外部未知扰动影响, 由式(2.2)、式(2.7)联立得到的空间机械臂系统的动力学方程为:

$$M(q)\ddot{q} + C(q, \dot{q})\dot{q} = u \quad (2.8)$$

其中, q 代表关节的位移、 $\dot{q}$ 代表关节的速度、 $\ddot{q}$ 代表关节的加速度, 矩阵 $M(q)$ 是机械臂系统的质量惯性矩阵, 矩阵 $C(q, \dot{q})$ 是离心力和哥氏力项, u 为空间机械臂控制输入力矩。

假设 2.1: 空间机械臂为刚性, 忽略结构柔性效应与分布式质量弹性振动模态; 各关节的控制输入互相独立, 不存在相互耦合或影响; 在模型中不考虑由于关节间物理连接引起的长度变化。

上述假设有效降低了高阶非线性空间机械臂系统的建模复杂度, 在拉格朗日建模体系下为后续控制器设计与稳定性分析提供理想化动力学环境。

那么:

$$\begin{aligned} M(q) &= \begin{bmatrix} (m_1 + m_2)l_1^2 + m_2l_2^2 + 2m_2l_1l_2\cos q_2 & m_2l_2^2 + m_2l_1l_2\cos q_2 \\ m_2l_2^2 + m_2l_1l_2\cos q_2 & m_2l_2^2 \end{bmatrix} \\ C(q, \dot{q}) &= \begin{bmatrix} -m_2l_1l_2\dot{q}_2\cos q_2 & -m_2l_1l_2(\dot{q}_1 + \dot{q}_2)\cos q_2 \\ -m_2l_1l_2\dot{q}_1\cos q_2 & 0 \end{bmatrix} \end{aligned}$$

令 $p_1 = (m_1 + m_2)l_1^2$, $p_2 = m_2l_2^2$, $p_3 = m_2l_1l_2$, 则

$$\begin{aligned} M(q) &= \begin{bmatrix} p_1 + p_2 + 2p_3\cos q_2 & p_2 + p_3\cos q_2 \\ p_2 + p_3\cos q_2 & p_2 \end{bmatrix} \\ C(q, \dot{q}) &= \begin{bmatrix} -p_3\dot{q}_2\cos q_2 & -p_3(\dot{q}_1 + \dot{q}_2)\cos q_2 \\ -p_3\dot{q}_1\cos q_2 & 0 \end{bmatrix} \end{aligned}$$

空间机械臂系统的动力学特征如下^[40]:

性质 1: 惯性矩阵 $M(q)$ 是对称正定矩阵, 满足如下不等式:

$$m_1\|x\|^2 \leq x^T M(q)x \leq m_2\|x\|^2$$

m_1 和 m_2 为正常数。

性质 2: $\dot{M}(q) - 2C(q, \dot{q})$ 是斜对称的, 满足如下关系式:

$$\alpha^T (\dot{M}(q) - 2C(q, \dot{q})) \alpha = 0, \forall \alpha \in R^n$$

这两个动力学性质为空间机械臂的稳定控制提供了数学基础，特别是在处理强非线性、参数不确定性和环境扰动时具有关键作用。这些性质不仅是理论分析的基石，更是工程实践中控制器设计和性能验证的核心依据。任何忽略这些性质的控制设计都可能导致稳定性丧失或性能恶化，尤其在空间应用等高可靠性场景中。

2.2 神经网络控制理论

在 20 世纪 40 年代初期，McCulloch 和 Pitts 通过形式化神经元的数学抽象，构建了基于阈值逻辑单元(Threshold Logic Unit, TLU)的离散神经网络计算框架，首次实现了生物神经系统信息处理机制的数理建模。该模型以布尔代数运算为基础，建立了神经元激活状态与逻辑命题间的映射关系，为后续计算神经科学奠定了理论基石。由于神经网络具备高度并行的架构、强大的学习与自适应能力、良好的故障容错特性以及出色的连续非线性函数逼近能力，在众多领域中获得了广泛关注与应用，尤其在非线性系统辨识与控制领域得到了巨大的发展与应用。神经网络作为不依赖精确数学建模的智能技术，凭借其独特的自主学习和误差补偿特性，在多个前沿领域展现出显著优势。该技术通过自主训练机制不断完善模型，并能有效逼近复杂系统偏差，这种特性使其在智能驾驶系统、现代化工业控制、金融风险预测、以及物联网感知系统等领域获得广泛应用。

自上世纪 80 年代误差反向传播(Backpropagation, BP)算法被提出以来，基于梯度优化的神经网络控制方法逐渐成为动态系统建模与非线性补偿的重要工具^[41-42]。该算法通过反向传递系统输出误差以动态调整网络权值参数，实现了对复杂非线性映射关系的逼近能力。20 世纪 90 年代，随着递归神经网络(Recurrent Neural Network, RNN)架构的引入，神经网络在处理时序信号方面展现出显著优势。进入 21 世纪，深度学习技术的突破性进展进一步推动了神经网络控制在计算机视觉、空间探索、人工智能等领域的应用。

在机器人运动控制领域，神经网络常被用于系统动态模型中不确定项的估计与补偿。具体而言，研究者通过构建具有在线学习能力的神经网络结构，对机械臂动力学模型中未建模的摩擦、负载扰动等非线性项进行实时逼近，并结合前馈补偿或自适应控制框架以提升轨迹跟踪精度。典型案例如：文献[43]针对机械臂末端轨迹跟踪过程中存在的建模误差与外部扰动问题，提出了一种基于自适应神经网络的滑模控制策略，通过融合神经网络逼近器与滑模鲁棒项，显著抑制了不确定因素对控制精度的影响；文献[44]则从分数阶微积分理论出发，设计了具有新型趋近律的滑模控制器，并引入径向基函数神经网络的自适应补偿机制，在降低逼近误差的同时提升了多关节机械臂轨迹跟踪系统的动态响应速度与鲁棒性。此类方法通过将数据驱动特性与传统模型驱动控制相结合，为解决复杂非线性系统的控制问题提供了创新性思路。

RBF(Radial Basis Function, 径向基函数)神经网络是一种前馈神经网络。RBF 神经

网络的典型结构由输入层、隐含层及输出层构成。一个多输入单输出的径向基神经网络的结构如图 2.2 所示：




图2.2 RBF神经网络结构图

Fig. 2.2 Structure of RBFNN

输入层：接收输入数据，将其传递给隐含层，节点数量与输入数据的维度相同，输入层中第 i 个输入表示为： x_i 。

隐含层：使用径向基函数作为激活函数。神经网络的激活函数以距离度量为核心，其输出由输入向量与网络中心点之间的相似性决定。这类函数具有局部响应特性，即仅在特定区域内对输入产生显著响应。以下是 RBF 神经网络常用的激活函数及其数学特性与作用机制的详细解析：

(1) 高斯函数(Gauss Function)

$$h(j) = \exp\left(-\frac{\|x - c_{ij}\|^2}{2\sigma_j^2}\right) \quad (2.9)$$

其中 x 为输入向量； c_j 为隐含层第 j 个神经元的中心； σ_j 为控制函数宽度的平滑参数； c_{ij} 表示为第 i 个输入在第 j 个高斯基函数上的中心向量。

特性：

对称性：以中心点 c_j 为对称轴，输出随距离增大指数衰减。

可导性：无限次可微，便于梯度计算。

局部性：仅在 c_j 附近产生显著非零值，远离中心的输入对输出影响极小。

可调性：通过调整 σ 控制函数的“宽度”（覆盖范围），小 σ 对应窄峰即高灵敏度，大 σ 对应宽峰即平滑响应。

应用场景：最广泛用于分类、回归和模式识别，尤其适合处理非线性可分问题

(2) 多二次函数(Multiquadrics Function)

$$h(j) = \sqrt{\|x - c_{ij}\|^2 + \sigma_j^2} \quad (2.10)$$

特性:

全局响应: 输出随欧式距离 $\|x - c_{ij}\|$ 单调递增, 无衰减特性。

插值能力: 适合解决全局逼近问题, 如曲面拟合; 满足某些插值问题的数学条件。

缺点: 计算复杂度较高, 可能导致数值不稳定。

(3) 逆多二次函数(Inverse Multiquadratics Function)

$$h(j) = \frac{1}{\sqrt{\|x - c_{ij}\|^2 + \sigma_j^2}} \quad (2.11)$$

特性:

衰减特性: 输出随欧氏距离 $\|x - c_{ij}\|$ 增大而减小, 类似于高斯函数, 但衰减速度更慢。

平滑性: 在全局范围内连续可导, 平衡了局部响应与全局平滑性, 适合需要平滑过渡的任务, 如信号处理。

高斯函数因其局部性、可导性和计算效率成为最常用的选择, 故本文研究采用高斯核函数构建 RBF 神经网络隐层基函数, 因为高斯形函数不仅表现形式简单, 同时不增加多变量输出的复杂性, 更重要的具备无穷阶连续可微特性, 为系统稳定性证明提供数学保障, 全局光滑的响应曲面特性确保理论分析框架的可解析性, 便于理论分析。

输出层: 对隐含层的输出进行线性组合, 得到最终的输出结果。输出层节点数量通常与输出数据的维度相同。 y_m 表示 RBF 神经网络的输出:

$$y_m(t) = w_1 h_1 + w_2 h_2 + \dots + w_n h_n \quad (2.12)$$

由高斯基函数的表达式可知, 高斯基函数的性能敏感性与中心矢量 c_i 和基宽度参数 σ 的取值有关。其中中心矢量 c_i 决定了多维特征空间中高斯核的几何中心位置, 其与输入向量 x 的欧氏距离 $\|x - c_i\|$ 构成核函数激活的判别依据, 此时敏感性与网络的输入值与 c_i 是否接近有关, 取值越接近越好, 反之就越差; 基宽度参数 σ 作为高斯基函数的形状调节因子, σ 的取值决定了高斯基函数形状的宽度。 σ 的取值的增大将导致高斯核的支撑集在输入空间呈现扩张趋势, 表现为函数覆盖域的增大和局部敏感性的降低, 当 σ 趋小时, 函数在特征空间中呈现高度局部化响应特性。

设网络的基宽向量为: $B = [\sigma_1, \sigma_2, \dots, \sigma_m]^T$, 这里 σ_j 为节点 j 的基宽参数。网络输出权重向量为: $W = [w_1, \dots, w_n]^T$

令 $y(t)$ 为期望目标输出, 定义损失函数 $E(t)$ 为均方误差的表达式如下所示, 从中可以看出神经网络的性能:

$$E(t) = \frac{1}{2} (y(t) - y_m(t))^2 \quad (2.13)$$

根据梯度下降法算法如下:

$$\Delta w_j(t) = -\eta \frac{\partial E}{\partial w_j} = \eta [y(t) - y_m(t)] h_j$$

$$w_j(t) = w_j(t-1) + \Delta w_j(t) + \alpha [w_j(t-1) - w_j(t-2)]$$

$$\Delta \sigma_j = -\eta \frac{\partial E}{\partial \sigma_j} = \eta [y(t) - y_m(t)] w_j h_j \frac{\|X - c_{ij}\|^2}{\sigma_j^3}$$

$$\sigma_j(t) = \sigma_j(t-1) + \Delta \sigma_j + \alpha [\sigma_j(t-1) - \sigma_j(t-2)]$$

$$\Delta c_{ij}(t) = -\eta \frac{\partial E}{\partial c_{ij}} = \eta [y(t) - y_m(t)] w_j h_j \frac{x_i - c_{ij}}{b_j^3}$$

$$c_{ij}(t) = c_{ij}(t-1) + \Delta c_{ij} + \alpha [c_{ij}(t-1) - c_{ij}(t-2)]$$

其中 η 为学习速率, α 为动量因子。

在非线性动力系统控制领域, 径向基函数(RBF)神经网络凭借其独特的数学构造优势, 已成为复杂系统建模的首选工具, 在各种非线性控制领域广泛应用。RBF 神经网络能够以确保对非线性连续泛函的全局逼近能力, 特别适用于非线性函数的逼近和建模; RBF 神经网络通常能够收敛到全局最优解而不是局部最优解, 这使得它在实际应用中更加可靠。

2.3 模糊神经网络控制理论

模糊 RBF 神经网络^[45-48](Fuzzy RBF Neural Network)是一种结合了模糊逻辑和径向基函数(RBF)神经网络的混合模型, 通过结合模糊逻辑的语义透明性和神经网络的强大学习能力, 在复杂系统建模中展现出独特优势, 是智能系统设计的重要工具。它融合了模糊逻辑处理不确定性信息的能力, 以及 RBF 神经网络强大的函数逼近和学习能力, 适用于具有强非线性、多扰动耦合特征的复杂动态系统控制任务。模糊 RBF 神经网络的结构如图 2.3 所示:

模糊径向基函数神经网络采用四层前馈结构实现非线性逼近, 各层级功能与信号传递机制可描述如下:

第 1 层: 信号输入层。输入层的不同节点直接接收待处理的外部输入信号, 输入层中第 i 个输入节点表示为: x_i 。

第 2 层: 模糊化层, 即隶属函数层。执行模糊化处理的核心功能层, 通过非线性变

换将输入量映射为隶属度值。常用的模糊化方法包括高斯隶属函数、三角隶属函数等。该层中采用隶属函数实现特征转换，常采用高斯函数作为隶属函数，该层输出结果反映了输入信号在模糊空间中的分布特性。

输入层第 i 个节点与模糊化层第 j 个节点的连接函数表示为：

$$s_{i,j} = \exp\left(-\frac{\|x_i - c_{ij}\|^2}{2b_j^2}\right)$$

式中： c_{ij} 为第 i 个输入信号的第 j 个模糊集合高斯函数的均值， b_j 为每个输入信号的第 j 个模糊集合高斯函数的宽度参数。

第 3 层：规则层，即模糊推理层。通过模糊逻辑运算实现规则激活强度的计算。该层神经元数量与隶属度层保持维度一致，每个规则节点的输出通过连乘运算实现模糊规则的触发强度计算。规则层节点个数与隶属函数层节点个数相等，因此规则层中第 j 个节点的输出为该节点所有输入信号的乘积，即：

$$S_j = \prod_{i=1}^N s_{i,j}$$

式中： $N = \prod_{i=1}^n N_i$ ， N_i 为输入层中第 i 个节点输入隶属函数的个数，即模糊化层节点数，该层输出本质上是多维隶属度空间的笛卡尔积运算结果。

第 4 层：输出层。输出层中每个节点的输出为该节点所有输入信号的加权和，即：

$$Y_l = W^T \cdot S_j = \sum_{j=1}^N W_{l,j} \cdot S_j \quad (2.14)$$

式中： l 为输出层节点的个数， W 为输出层节点与规则层节点的连接权值矩阵。




图2.3 模糊神经网络结构图

Fig. 2.3 Structure diagram of fuzzy neural network

通过结合模糊逻辑的语义透明性和神经网络的强大学习能力,模糊神经网络在复杂系统建模中展现出独特优势,成为智能系统设计的重要工具。文献[49]已经证明,模糊神经网络可以在紧集上以任意精度逼近任何实连续函数。因此,对于定义在紧集上的任意实值连续函数,存在一个模糊神经网络函数 $f(z)$,其可通过调整隶属度函数参数及连接权值,以任意给定精度逼近目标函数,即

$$f(z) = W^T \cdot S(z) + \varepsilon(z) \quad (2.15)$$

其中 W 是模糊神经网络理想权值, $S(z)$ 是模糊基函数, $\varepsilon(z)$ 是模糊神经网络的建模误差。

2.4 模型预测控制理论

模型预测控制^[50-53]即 MPC(Model Predictive Control),MPC 是一种基于系统模型、滚动时域优化和反馈校正的先进控制策略,其核心机理是通过求解有限时域内的最优控制序列,实现对多变量、非线性及受约束复杂系统的高精度控制,广泛应用于工业过程控制。MPC 通过模型、预测和控制三个部分实现先进控制,其典型控制流程可分解为预测建模、滚动优化与反馈校正三个递进阶段:首先构建系统动态特性的数学模型,继而基于当前状态预测未来时域内的系统行为,最后通过求解带约束的优化问题获取最优控制量序列,并采用首项控制策略实现执行器输出。在模型预测控制中,针对线性时不变系统多采用二次规划(Quadratic Programming, QP)求解;针对非线性系统则需构建非线性规划(Nonlinear Programming, NLP)问题;对于特定马尔可夫决策过程,动态规划(Dynamic Programming, DP)方法展现出理论优势。MPC 能够处理约束,适用于多变量和非线性系统,尽管计算复杂度较高,但在工业控制中具有广泛的应用前景。

第一步聚焦于系统动态模型的精确构建,模型是 MPC 的基础,用于描述被控对象的动态行为。模型可以是线性的或非线性的,具体形式取决于被控对象的特性。假设被控对象的线性数学模型如下:

$$y(k) = au(k) \quad (2.16)$$

其中 $y(k)$ 为系统输出, a 为线性参数, $u(k)$ 为系统的控制输入。假设预测步长为 p 步,系统控制输出为:

$$y(k+1), y(k+2), \dots, y(k+p) \quad (2.17)$$

假设控制步长为 m 步,系统控制输入为:

$$u(k), u(k+1), \dots, u(k+m-1) \quad (2.18)$$

由于模型为线性系统,基于线性系统的叠加原理,系统预测输出可解析为由初始状态引起的自由响应和由控制输入引起的受迫响应的线性组合,即:

$$\begin{cases} y(k) = a_1 u(k-1) + a_2 u(k-2) + \dots + a_m u(k-m) \\ \Delta y(k) = a_1 \Delta u(k-1) + a_2 \Delta u(k-2) + \dots + a_m \Delta u(k-m) \end{cases} \quad (2.19)$$

第二步对上述模型的状态进行预测, 预测是 MPC 的核心功能之一。基于当前状态和控制输入, 利用模型预测系统在未来一段时间内的行为。根据预测步长 p 和控制步长 m , 在第 k 时刻的系统控制输入会对下一时刻的控制输出有如下影响, 表示为:

$$\begin{cases} \Delta y(k+1) = a_1 \Delta(k) \\ \Delta y(k+2) = a_1 \Delta(k) + a_2 \Delta(k+1) \\ \vdots \\ \Delta y(k+p) = a_1 \Delta(k+p-1) + a_2 \Delta(k+p-2) + \dots + a_m \Delta(k+p-m) \\ = \sum_{i=1}^m a_i \Delta(k+p-i) \end{cases}$$

使用原有的预测输出与控制输出可以得到新的预测输出, 其表达式如下:

$$Y_n = A\Delta u + Y \quad (2.20)$$

其中 Y_n 为新的预测输出矩阵, Y 为原有的预测输出矩阵, $A\Delta u$ 为控制输出矩阵, 将上式用矩阵展开, 其表示如下:

$$\begin{bmatrix} Y_n(k+1) \\ Y_n(k+2) \\ \vdots \\ Y_n(k+p) \end{bmatrix} = \begin{bmatrix} a_1 & 0 & \dots & 0 \\ a_2 & a_1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ a_p & a_{p-1} & \dots & a_{p-m+1} \end{bmatrix} \begin{bmatrix} \Delta u(k) \\ \Delta u(k+1) \\ \vdots \\ \Delta u(k+m) \end{bmatrix} + \begin{bmatrix} Y(k+1) \\ Y(k+2) \\ \vdots \\ Y(k+p) \end{bmatrix}$$

第三步进行滚动时域优化。

首先针对期望输出方面, 可以使用一阶指数加权滤波进行优化, 优化后的控制输出采用递推形式构建, 其数学表征如下所示:

$$w(k+i) = \alpha^i y(k) + (1-\alpha^i) y_d(k) \quad (2.21)$$

其中 y_d 为期望轨迹参考量, w 为优化后的控制输出, α 为优化参数其范围 $[0,1]$, 特别地, 当 $\alpha \rightarrow 0^+$ 时, 历史输出 $y(k)$ 的权值快速衰减, 系统呈现强跟踪特性; 而当 $\alpha \rightarrow 1^-$ 时, 优化输出呈现渐进平滑特性, 可以有效抑制高频噪声干扰。

在滚动优化框架下, 系统通过求解带约束的二次规划问题生成最优控制序列。目标函数定义为跟踪误差与控制增量惩罚项的加权和, 表达式如下:

$$J = q \sum_{i=1}^p (y_d(k+i) - w(k+i))^2 + r \sum_{i=1}^m (\Delta u(k+i-1))^2 \quad (2.22)$$

其中 q 与 r 为权重系数, 增大 q 可以加强系统的跟踪性能, 增大 r 可以优化系统的控制输入, 将上式转换成矩阵形式表达如下:

$$J = (Y - W)^T Q (Y - W) + \Delta u^T R \Delta u \quad (2.23)$$

其中 $Y - W$ 为 $p \times 1$ 的矩阵; $Q = \text{diag}(q, q, \dots, q)$ 为 $p \times p$ 的矩阵, 是输出跟踪误差的正定权重

矩阵； $R = \text{diag}(r, r, \dots, r)$ 为 $m \times m$ 的矩阵，是控制输入的正定权重矩阵； Δu 为 $m \times 1$ 的矩阵；对目标函数 J 求偏导可以解析获得最优控制序列。

第四步误差校正，为进一步增强鲁棒性，系统引入动态误差补偿机制。在第 $k+1$ 时刻通过实际输出测量值 y_d 与预测值 y_n 的偏差进行补偿：

$$e(k+1) = y_d(k+1) - y_n(k+1) \quad (2.24)$$

使用误差对新的预测输出进行控制补偿，可以得到补偿过后的预测控制输出 y_{cor} 表示如下：

$$\begin{cases} y_{cor}(k+1) = y_n(k+1) + h_1 e(k+1) \\ y_{cor}(k+2) = y_n(k+2) + h_2 e(k+1) \\ \vdots \\ y_{cor}(k+p) = y_n(k+p) + h_p e(k+1) \end{cases}$$

其中 h 为预测模型的误差补偿系数，用于将当前时刻的误差 $e(k+1)$ 分配到未来 p 步的预测输出中，以修正模型失配或外部扰动的影响。

当对当前预测输出进行补偿后，需要对预测输出矩阵进行移位操作，通过移位矩阵 S 更新预测窗口，实现对下一时刻的预测，表示如下：

$$Y_n = S Y_{cor} \quad (2.25)$$

2.5 本章小结

作为一类具有强非线性、多自由度耦合特性的空间操作机构，空间机械臂的高精度轨迹跟踪控制需基于其多体动力学特性构建精确数学模型，并设计控制策略以克服参数不确定性、关节柔性及外界扰动等复杂因素的影响。本章基于拉格朗日力学原理，推导了双关节刚性空间机械臂的动力学方程，随后系统阐释了神经网络逼近机理、模糊径向基函数网络控制策略及模型预测控制方法的核心原理，为后续实现高精度轨迹跟踪控制构建了方法体系与实施框架。

3 空间机械臂的模糊神经网络控制

3.1 引言

模糊神经网络是一种基于模糊集合理论与神经网络架构深度融合的混合计算模型，其通过模糊规则库与隶属度函数的自适应学习机制，构建具有多层次非线性映射能力的智能系统。相较于 RBF 神经网络和独立模糊逻辑系统，模糊神经网络通过模糊化层、规则推理层及去模糊化层的协同优化，能够在高维特征空间中实现更优的全局逼近性能，尤其适用于复杂非线性系统的建模与控制问题。由于这一优点，模糊神经网络已成为补偿参数不确定性、外部干扰和输入死区的理想工具。

综上，基于第二章建立的空间机械臂动力学模型，本章节针对自身参数不确定且存在输入死区的空间机械臂系统，设计了一种自适应模糊 RBF 神经网络控制策略。

3.2 问题描述

输入死区是控制工程、信号处理和机电系统中常见的非线性特性，死区通常表现为执行器的非线性特性。死区指的是在输入信号变化到一定范围内时，系统的输出没有任何反应或反应被抑制。对于许多物理装置，当控制输入信号达到特定值之前，它们的输出为零，这种输入输出关系称为死区。从数学意义上讲，死区是一种非线性函数，反映了系统对小信号的不敏感度。在大多数闭环系统中，死区对系统暂态及稳态性能均有不良影响。这种非线性滞环现象会显著降低闭环控制系统的动态调节能力和稳态精度，当工作点进入死区区间时，不仅会导致有效控制量衰减，还可能引发极限环振荡或轨迹跟踪偏差累积等问题。输入死区数学模型如图 3.1 所示。




图3.1 输入死区数学模型

Fig. 3.1 Enter the dead zone mathematical model

死区特性的数学特性由下式给出:

$$D(u) = \begin{cases} g(u) & u < 0 \\ 0 & u = 0 \\ h(u) & u > 0 \end{cases} \quad (3.1)$$

其中 u 是输入信号, $h(u)$ 和 $g(u)$ 是两个非线性函数, τ 为死区的输出。基于数学特性假设函数 $h(u)$ 和 $g(u)$ 是满足严格单调、连续可导且可逆。据此可构造其对应的逆模型 $D^{-1}(u)$, 死区环节的逆可表示为如下的等价形式:

$$D^{-1}(u) = \begin{cases} g^{-1}(u) & u < 0 \\ 0 & u = 0 \\ h^{-1}(u) & u > 0 \end{cases} \quad (3.2)$$

基于第二章建立的空间机械臂模型, 为了简化分析, 本章节研究的机械臂系统仅考虑外部干扰, 不考虑摩擦力项, 那么机械臂的动力学模型可以写为:

$$M(q)\ddot{q} + C(q, \dot{q})\dot{q} + \tau_d = D(u) \quad (3.3)$$

其中, q 代表关节的位移、 $\dot{q}$ 代表关节的速度、 $\ddot{q}$ 代表关节的加速度, 矩阵 $M(q)$ 是机械臂系统的质量惯性矩阵, 矩阵 $C(q, \dot{q})$ 是离心力和哥氏力项, τ_d 为外部未知干扰, $D(u)$ 为空间机械臂控制输入力矩。

控制目标: 为了抵消未知死区非线性的有害影响, 为了补偿未知死区的非线性影响, 将模糊神经网络补偿器设置在死区环节的前端, 对死区非线性环节进行补偿。设计如图 3.2 所示的模糊神经网络控制器, 模糊神经网络分别用于补偿系统不确定性和输入死区。其中 τ_c 是模糊神经网络控制器的输出, 即为估计系统集总不确定性的理想控制输入; u 为死区补偿后的机械臂控制输入; τ 为经过死区后的实际控制输入。目标是确保经过输入死区后的输出 τ 能够精确跟踪控制器输出 τ_c , 从而维持闭环系统的跟踪精度与稳定性。




图3.2 模糊神经网络控制器

Fig. 3.2 Fuzzy neural network controller

针对模糊神经网络参数的有界性特征, 本研究设定以下基本约束条件:

假设 3.1: 模糊神经网络理想权值 W_c 、 W_s 和 W 满足范数约束, 即存在正常数 W_{cM} 、 W_{sM} 、 W_M , 分别满足 $\|W_c\| \leq W_{cM}$ 、 $\|W_s\| \leq W_{sM}$ 、 $\|W\| \leq W_M$ 。

假设 3.2: 对于理想权值 W_c 、 W_s 和 W 对应的估计误差 ε_c 、 ε_s 、 ε 存在确定的正实数边界 ε_{cM} 、 ε_{sM} 、 ε_M , 满足 $\|\varepsilon_c\| < \varepsilon_{cM}$ 、 $\|\varepsilon_s\| < \varepsilon_{sM}$ 、 $\|\varepsilon\| < \varepsilon_M$ 。

假设 3.1 与假设 3.2 为后续 Lyapunov 稳定性证明提供数学基础并且确保闭环系统状态不会发散。

3.3 针对建模误差的模糊神经网络控制器设计

设空间机械臂系统给定理想轨迹为 q_d , q 为机械臂实际的关节位置, 定义空间机械臂轨迹跟踪误差及其微分形式为:

$$\begin{aligned} e(t) &= q_d(t) - q(t) \\ \dot{e}(t) &= \dot{q}_d(t) - \dot{q}(t) \end{aligned} \quad (3.4)$$

构造滑模误差函数以增强系统动态响应特性:

$$r = \dot{e} + \Lambda e \quad (3.5)$$

那么误差函数 r 的导数为:

$$\dot{r} = \ddot{e} + \Lambda \dot{e} \quad (3.6)$$

其中 Λ 为正定对角增益矩阵, $\Lambda = \Lambda^T > 0$, 由式(3.4)与式(3.6)得:

$$\dot{q} = -r + \dot{q}_d + \Lambda e \quad (3.7)$$

则

$$\begin{aligned} M\dot{r} &= M(\ddot{e} + \Lambda \dot{e}) \\ &= M(\dot{q}_d - \ddot{q} + \Lambda \dot{e}) \\ &= M(\ddot{q}_r) + C\dot{q} + \tau_d + D(u) \\ &= M(\ddot{q}_r) - Cr + C(\dot{q}_r) + \tau_d + D(u) \\ &= -Cr + \tau_d - D(u) \end{aligned}$$

针对空间机械臂模型参数不确定性与外部扰动耦合问题, 定义需要补偿的复合不确定项为:

$$f = M\dot{r} + Cr + \tau_d \quad (3.8)$$

由于现有测量手段很难获得空间机器人精确的数学模型, 设系统需要补偿的误差模型为 f 。本节首先利用模糊神经网络对模型不确定部分 f 进行补偿, 则模糊神经网络的理想输出为:

$$f = W_c^T \cdot S_c(x) + \varepsilon_c(x) \quad (3.9)$$

其中 $\varepsilon_c(x)$ 是模糊神经网络对不确定项 f 的建模误差。

定义 W_c 为模糊神经网络的理想权值, 定义 $\hat{W}_c$ 为模糊神经网络的估计权值, 定义 $\tilde{W}_c$ 为模糊神经网络的权值估计误差, 则

$$\tilde{W}_c = W_c - \hat{W}_c \quad (3.10)$$

$\hat{f}$ 为模糊 RBF 神经网络对不确定项 f 的逼近值:

$$\hat{f} = \hat{W}_c^T \cdot S_c(x) \quad (3.11)$$

针对空间机械臂模型参数不确定性与外部扰动问题, 设计模糊神经网络控制器控制律为:

$$\tau_c = \hat{f} + K_v r + v_c \quad (3.12)$$

估计误差为 $\tilde{f} = f - \hat{f}$, $\tilde{f} \leq f_M(x)$, K_v 为正定对角矩阵, v_c 为用于克服建模不确定性的鲁棒项。

鲁棒控制律设计为:

$$v_c(t) = -f_M(x) \operatorname{sgn}(r) \quad (3.13)$$

其中 $\operatorname{sign}(\cdot)$ 为符号函数。符号函数(Sign Function)是数学和工程领域中广泛使用的一种分段函数, 其核心作用是根据输入值的符号输出特定的离散值。该函数在控制系统、信号处理、优化算法等领域具有重要应用, 尤其在处理非线性特性和切换逻辑时表现突出。




图3.3 符号函数

Fig. 3.3 sign function

控制器模糊神经网络自适应律设计为

$$\dot{\hat{W}}_c = K_0^T S_c(w) r^T \quad (3.14)$$

$K_0^T = K_0$ 为正定对称矩阵。

3.4 针对输入死区的模糊神经网络补偿控制

死区补偿器的控制目标是补偿控制器的输出 τ_c 使其克服死区的不良影响, 最终与经执行机构后的输出 τ 一致。

对空间机械臂死区环节进行补偿的目标是使下式成立:

$$D(\tau_c + \tau_s) = \tau_c \quad (3.15)$$

死区环节的逆可以表示为:

$$D^{-1}(\tau_c) = \tau_c + \tau_s \quad (3.16)$$

采用模糊 RBF 神经网络逼近死区逆模型, 其理想输出为:

$$D^{-1}(\tau_c) = \tau_c + \tau_s = \hat{W}_s^T S_s(\tau_c) + \varepsilon_s(\tau_c) \quad (3.17)$$

式中 $\varepsilon_s(\tau_c)$ 为逼近误差, 满足 $\|\varepsilon_s\| \leq \varepsilon_{s\max}$ 。

定义模糊神经网络死区补偿器输出为:

$$\hat{\tau}_s = \hat{W}_s^T S_s(\tau_c) \quad (3.18)$$

那么补偿后的执行器实际输入为控制器输入与死区补偿器输入之和, 即:

$$u = \tau_c + \hat{\tau}_s \quad (3.19)$$

对死区环节进行估计的模糊神经网络最优输出:

$$D(u) = W^T S(u) + \varepsilon(u) \quad (3.20)$$

模糊神经网络死区补偿器的估计输出为:

$$\hat{D}(u) = \hat{W}^T S(u) \quad (3.21)$$

定义 $\hat{W}$ 和 $\hat{W}_s$ 为模糊神经网络理想权值的估计值, 定义 $\tilde{W}$ 、 $\tilde{W}_s$ 为模糊神经网络的权值估计的误差值, 则

$$\tilde{W} = W - \hat{W}$$

$$\tilde{W}_s = W_s - \hat{W}_s$$

推导死区输出 τ 与神经网络死区补偿器 τ_s 及控制器输出 τ_c 的关系为:

$$\tau = \tau_c + S_s(\tau_c) - \hat{W}_s^T S_s(\tau_c) \quad (3.22)$$

模糊神经网络死区补偿器自适应控制律设计为:

$$\dot{\hat{W}} = K_1 S(u) r^T \quad (3.23)$$

$$\dot{\hat{W}_s} = K_2 S_s(\tau_c) r^T \quad (3.24)$$

其中, $K_1 = K_1^T$, $K_2 = K_2^T$ 为正定常量对称矩阵, $K_1, K_2 > 0$ 。

3.5 模糊 RBF 神经网络控制稳定性分析

定理 3.1: 对于空间机械臂系统(3.3), 在满足假设 3.1、假设 3.2 的情况下, 采用模糊神经网络控制器(3.12)、死区补偿器(3.18), 权重自适应更新律式(3.14)、式(3.23)、式(3.24)可以实现机械臂系统的闭环跟踪误差最终一致有界稳定, 且轨迹跟踪误差随着增益 $K_v > 0$ 的增加而逐渐收敛。

证明:

选取 Lyapunov 函数为:

$$V = \frac{1}{2} r^T M r + \frac{1}{2} \text{tr}(\tilde{W}^T K_1 \tilde{W}) + \frac{1}{2} \text{tr}(\tilde{W}_s^T K_2 \tilde{W}_s) \quad (3.25)$$

对 V 两边进行展开时间导数得:

$$\dot{V} = \frac{1}{2} r^T \dot{M} r + \frac{1}{2} r^T \dot{M} r + \frac{1}{2} \text{tr}(\tilde{W}^T K_1 \dot{\tilde{W}}) + \frac{1}{2} \text{tr}(\tilde{W}_s^T K_2 \dot{\tilde{W}}_s) \quad (3.26)$$

机械臂动力学方程可改写为:

$$\dot{M} r = -C r - f - K_v r \quad (3.27)$$

利用机械臂性质 2: $\dot{M}(q) - 2C(q, \dot{q})$ 是斜对称的可得:

$$r^T (\dot{M} - 2C) r = 0$$

即

$$r^T \dot{M} r = r^T 2C r \quad (3.28)$$

将式(3.27)、式(3.28)代入式(3.26)得:

$$\dot{V} = r^T (-C r - f - K_v r) + r^T C r + \text{tr}(\tilde{W}^T K_1 \dot{\tilde{W}}) + \text{tr}(\tilde{W}_s^T K_2 \dot{\tilde{W}}_s)$$

进一步化简为:

$$\dot{V} = -r^T K_v r - r^T f + \text{tr}(\tilde{W}^T K_1 \dot{\tilde{W}}) + \text{tr}(\tilde{W}_s^T K_2 \dot{\tilde{W}}_s) \quad (3.29)$$

将式(3.11)、式(3.18)代入式(3.29)得:

$$\dot{V} = -r^T K_v r - r^T (\hat{W}_c^T \cdot S_c(x) + \varepsilon_c(x) - \hat{W}_c^T \cdot S_c(x)) + \text{tr}(\tilde{W}^T K_1 \dot{\tilde{W}}) + \text{tr}(\tilde{W}_s^T K_2 \dot{\tilde{W}}_s) \quad (3.30)$$

由迹运算性质 $\text{tr}(AB) = \text{tr}(BA)$ 得:

$$\begin{aligned} -r^T \tilde{W}^T S &= -\text{tr}(\tilde{W}^T S r^T) \\ -r^T \tilde{W}_s^T S_s &= -\text{tr}(\tilde{W}_s^T S_s r^T) \end{aligned}$$

将模糊神经网络自适应律将式(3.23)、式(3.24)带入式(3.30)可得:

$$\begin{aligned} \dot{V} &= -r^T K_v r - r^T (\varepsilon_c(x) + \varepsilon(u)) - \text{tr}(\tilde{W}^T S r^T) - \text{tr}(\tilde{W}_s^T S_s r^T) \\ &\quad + \text{tr}(\tilde{W}^T K_1 (-K_1 S r^T)) + \text{tr}(\tilde{W}_s^T K_2 (-K_2 S_s r^T)) \end{aligned}$$

上式可以进一步整理为:

$$\begin{aligned}\dot{V} &= -r^T K_v r - r^T (\varepsilon_c(x) + \varepsilon(u)) \\ &\leq -\lambda_{\min} K_v \|r\| + \|r\| (\varepsilon_{c\max} + \varepsilon_{\max})\end{aligned}\quad (3.31)$$

其中 $\lambda_{\min} K_v$ 是 K_v 的最小特征值。

由 Barbalat 引理: 若 $V(t) \geq 0$ 且 $\dot{V}(t) \leq -\alpha V(t) + \beta$, 则 $V(t)$ 指数收敛至有界区域; 对式(3.31)进行积分得:

$$V(t) \leq V(0) - \lambda_{\min} K_v \int_0^t \|r(\varsigma)\| d\varsigma + (\varepsilon_{c\max} + \varepsilon_{\max}) t \quad (3.32)$$

当 $t \rightarrow \infty$ 时, $r(t)$ 一致最终有界, 且可以通过增加增益 $K_v > 0$ 来使跟踪误差 r 为任意小。因此, 将控制器和补偿器看作空间机械臂的整体控制部分, 根据 Lyapunov 理论证明了闭环系统的跟踪误差是一致最终有界稳定的。

3.6 仿真实验

为了验证所提出控制方案的有效性, 本小节利用 MATLAB 构建了双关节刚性机械臂的数值仿真环境, 空间机械臂的结构图如图 2.1 所示。空间机械臂的模型参数设置为 $m_1 = 2.04\text{kg}$; $m_2 = 1\text{kg}$; $l_1 = 1\text{m}$; $l_2 = 0.87\text{kg}$; $p = [p_1, p_2, p_3] = [2.9, 0.76, 0.87]$ 。机械臂的初始状态设定位于零位置, 选择死区参数为 $d_+ = 10$, $d_- = -10$ 。期望轨迹为 $q_d(t) = [0.1\sin(t) \quad 0.1\sin(t)]^T$, 模糊神经网络的参数选择为 $\Lambda = \Lambda^T = \text{diag}[5, 0]$ 。

为了验证模糊 RBF 神经网络控制算法的性能, 在 MATLAB 的 Simulink 环境中搭建基于模糊 RBF 神经网络的二连杆空间机械臂仿真模型, 如图 3.4 所示。在进行模糊神经网络控制器(FNN Controller)的仿真验证时, 设置 RBF 神经网络控制器(NN Controller)作为对照组进行对比验证, 为了验证所设计模糊神经网络控制方案的优越性, 两种控制方案使用相同的机械臂的参数来实现公平性。




图3.4 模糊RBF神经网络仿真模型

Fig. 3.4 Fuzzy RBF neural network simulation model

空间机械臂系统的仿真结果如图 3.5-3.9 所示：




图3.5 空间机械臂3D仿真

Fig. 3.5 3D simulation of space manipulator




图3.6 空间机械臂的位置跟踪

Fig. 3.6 Position tracking of space manipulator




图3.7 空间机械臂的速度跟踪

Fig. 3.7 Speed tracking of space manipulator

图 3.6 表示为在两种控制方案下空间机械臂的轨迹跟踪的效果。图中红线代表期望的空间机械臂轨迹路线，蓝线为 RBF 神经网络控制下的轨迹跟踪，绿线为模糊 RBF 神

神经网络控制下的轨迹跟踪。由图 3.6 分析可知,在初始阶段两种控制方案均有一定的轨迹跟踪误差,但在较短的时间内快速收敛到期望的轨迹。对比可知,模糊 RBF 神经网络方案控制下的机械臂两个关节超调量比 RBF 神经网络方案减少了 50%,并且响应速度提高了 60%,显著减少了空间机械臂系统的震荡环节。

图 3.7 表示为在两种控制方案下空间机械臂的速度跟踪的效果。图中红线代表期望的空间机械臂的期望速度,蓝线为 RBF 神经网络控制下的速度跟踪,绿线为模糊 RBF 神经网络控制下的速度跟踪。由图 3.7 分析可知,在初始阶段两种控制方案初始速度均有一定的跟踪误差,但在较短的时间内快速收敛,达到机械臂期望的速度。对比可知,模糊 RBF 神经网络方案控制下的机械臂两个关节超调量均比 RBF 神经网络方案更小,并且响应速度更快,由跟踪响应易证,所提出的模糊 RBF 神经网络控制器可以实现比 RBF 神经网络控制器更高的跟踪精度,更快的跟踪响应,更少的震荡环节。这证明了模糊 RBF 神经网络对空间机械臂系统的控制是有效的,具有更好的全局逼近性能,可以提高控制器的跟踪性能。




图3.8 空间机械臂死区及其估计

Fig. 3.8 Dead zone of space manipulator and its estimation




图3.9 空间机械臂的输入力矩

Fig. 3.9 Input torque of the space manipulator

图 3.8 表示为模糊 RBF 神经网络对空间机械臂死区环节的估计值，红线为利用 simulink 死区模块设置的死区环节，蓝线表示为模糊 RBF 神经网络对死区的估计值。从图 3.8 中可以看出，神经网络死区补偿器能够较好地补偿实际死区所造成的影响，从而提高轨迹跟踪控制的精度。通过轨迹跟踪和速度跟踪图中也可以看出，所设计的控制器可以快速高效的完成目标跟踪。

图 3.9 为空间机械臂的输入力矩图。图中蓝线为空间机械臂的理想控制输入 τ_c ，红线为经过补偿的实际控制输入 u 。由图 3.9 分析可得，在未对空间机械臂进行死区补偿的情况下，理想控制输入受到输入死区的影响，出现了输入信号失灵的现象；而通过对死区进行的补偿，关节 1、2 的理想控制输入 τ_c 与经过死区后实际的控制输出 τ 相比达到了很好的吻合，克服了死区环节的不良影响，从而使空间机械臂的轨迹跟踪控制获得了快速精准的控制效果。

3.7 本章小结

本章主要内容是针对存在输出死区的空间机械臂的进行轨迹跟踪控制，同时考虑了存在外部干扰的情况，使得空间机械臂的轨迹跟踪控制问题更具有实际意义。基于模糊逻辑系统的启发式决策优势与径向基函数(RBF)神经网络的快速泛化特性，提出了一种

新的自适应模糊神经网络控制方案，同时考虑了空间机械臂系统特有的模型不确定性和输入死区问题，采用李雅普诺夫方法证明了系统的稳定性。仿真研究通过对比分析 RBF 神经网络、模糊 RBF 神经网络控制方法控制下的二连杆机械臂的位置跟踪曲线及跟踪误差发现，模糊 RBF 神经网络控制的响应时间更短，有效抑制了机械臂系统的震荡环节，且达到了更低的稳态误差、控制性能更加精确高效，实现了空间机械臂的高精度轨迹跟踪控制。

4 空间机械臂的神经网络模型预测跟踪控制

4.1 引言

在考虑外部扰动因素的情况下, 为了提高空间机械臂轨迹跟踪的精度, 本章节提出了一种新的基于 RBF 神经网络的模型预测控制算法。首先通过零阶保持器方法将空间机械臂的动力学模型转换为离散方程式, 随后利用模型预测控制将空间机械臂的轨迹跟踪控制转化为动态优化问题, 然后通过 RBF 神经网络实时逼近和最小化模型预测控制的代价函数来优化空间机械臂的轨迹跟踪控制, 最后过对二连杆空间机械臂进行 MATLAB 仿真实验, 验证了所设计的控制算法的有效性。

4.2 问题描述

基于第二章建立的空间机械臂模型, 本节研究的机械臂系统考虑外部干扰与摩擦力项, 那么机械臂的动力学模型可以写为:

$$M(q)\ddot{q} + C(q, \dot{q})\dot{q} + F(\dot{q}) + \tau_d = u \quad (4.1)$$

其中, q 代表关节的位移、 $\dot{q}$ 代表关节的速度、 $\ddot{q}$ 代表关节的加速度, 矩阵 $M(q)$ 是机械臂系统的质量惯性矩阵, 矩阵 $C(q, \dot{q})$ 是离心力和哥氏力项, 矩阵 $F(\dot{q})$ 是摩擦力项, τ_d 为外部未知干扰, u 为空间机械臂控制输入力矩。

首先, 定义状态向量 $x = [x_1 \ x_2]^T = [q \ \dot{q}]^T$, 那么 $\dot{x}_1 = x_2$, 联立式(4.1)得:

$$\dot{x}_2 = \ddot{q} = M^{-1}(u - \tau_d - C(q, \dot{q})\dot{q} - F(\dot{q})) \quad (4.2)$$

该机械臂系统的状态空间方程为:

$$\begin{cases} \dot{x} = f(x, u) \\ f(x, u) = [\dot{q} \ M^{-1}(u - \tau_d - C(q, \dot{q})\dot{q} - F(\dot{q}))]^T \end{cases} \quad (4.3)$$

在系统平衡点 $(x_0 \ u_0)$ 对 $f(x, u)$ 进行一阶泰勒展开:

$$\dot{x} \approx f(x_0, u_0) + \frac{\partial f}{\partial x} \Big|_{x_0, u_0} (x - x_0) + \frac{\partial f}{\partial u} \Big|_{x_0, u_0} (u - u_0) \quad (4.4)$$

D_d 包含泰勒展开的高阶项或未建模扰动的常数项, 则空间机械臂的动力学模型在平衡点附近线性化后为:

$$\dot{x} \approx A_d (x - x_0) + B_d (u - u_0) + D_d \quad (4.5)$$

$$\text{其中 } A_d = \frac{\partial f}{\partial x} = \begin{bmatrix} 0 & I \\ -M^{-1} \frac{\partial}{\partial q} (C\dot{q} + F) & -M^{-1} (C + B_d) \end{bmatrix}, \quad B_d = \frac{\partial f}{\partial u} = \begin{bmatrix} 0 \\ M^{-1} \end{bmatrix}.$$

为实现模型预测控制器设计以及后续滚动优化过程,需将连续时间模型转换为离散时间状态方程,采用零阶保持器将空间机械臂控制系统动力学模型离散化过程如下。

假设控制输入 $u(t)$ 在采样间隔 $[k\Delta T, (k+1)\Delta T]$ 内保持恒定(零阶保持器假设),即 $u(t) = u(k)$, 那么系统解可表示为:

$$x(k+1) = e^{A_d \Delta T} x(k) + \int_{k\Delta T}^{(k+1)\Delta T} e^{A_d[(k+1)\Delta T - \tau]} (B_d u(k) + D_d) d\tau \quad (4.6)$$

τ 是积分操作中的哑变量(dummy variable),代表积分区间内的任意时间点。在离散化过程中, τ 用于计算从连续时间到离散时间的累积效应。令 $\tau' = (k+1)\Delta T - \tau$ 。则积分限变为 $\tau' = 0$ 到 $\tau' = \Delta T$, 积分 $\int_{k\Delta T}^{(k+1)\Delta T} e^{A_d[(k+1)\Delta T - \tau]} (B_d u(k) + D_d) d\tau$ 简化为:

$$\int_0^{\Delta T} e^{A_d \tau'} d\tau' \cdot B_d u(k) + \int_0^{\Delta T} e^{A_d \tau'} d\tau' \cdot D_d$$

若 A_d 可逆, 矩阵指数的积分满足:

$$\int_0^{\Delta T} e^{A_d \tau} d\tau = A_d^{-1} (e^{A_d \Delta T} - I) \quad (4.7)$$

将积分结果式(4.7)带入离散方程式(4.6)得:

$$x(k+1) = e^{A_d \Delta T} x(k) + A_d^{-1} (e^{A_d \Delta T} - I) B_d u(k) + A_d^{-1} (e^{A_d \Delta T} - I) D_d \quad (4.8)$$

最终得到离散化后的系统方程为:

$$x(k+1) = Ax(k) + Bu(k) + D(k) \quad (4.9)$$

式中 $A = e^{A_d \Delta T}$ 为离散状态矩阵, $B = A_d^{-1} (e^{A_d \Delta T} - I) B_d$ 为离散输入矩阵, $D = A_d^{-1} (e^{A_d \Delta T} - I) D_d$ 为等效离散扰动, ΔT 为采样时间。

控制目标: 首先通过模型预测控制将空间机械臂的轨迹跟踪控制转化为动态优化问题; 其次在经典的模型预测控制基础上, 采用 RBF 神经网络逼近和最小化模型预测控制的代价函数来优化空间机械臂的控制输入。

4.3 空间机械臂的模型预测控制

在空间机械臂的系统预测模型建立后, 当系统运行至 k 时刻, 施加控制指令序列 $U(k)$, 预测模型向后预测 N_p 步可以得到 k 时刻预测的输入输出以及预测状态序列。模型预测控制的核心思想在于: 构造包含控制能量消耗与轨迹误差的优化指标函数, 在满足系统物理约束的前提下, 通过滚动优化算法实时求解最优控制序列, 最终实现机械臂末端执行器的高精度轨迹跟踪。

对于空间机械臂系统, 在 k 时刻预测模型的控制输入序列为:

$$U(k) = \begin{bmatrix} u(k|k) \\ u(k+1|k) \\ u(k+2|k) \\ \vdots \\ u(k+N_p-1|k) \end{bmatrix}$$

基于初始状态 $x(k|k)$ 和控制序列 $U(k)$, 调用预测模型, 得到未来 N_p 步的状态序列:

$$X(k+1) = \begin{bmatrix} x(k+1|k) \\ x(k+2|k) \\ x(k+3|k) \\ \vdots \\ x(k+N_p|k) \end{bmatrix}$$

在 k 时刻预测模型 $k+1$ 时刻的输出序列为:

$$Y(k+1) = \begin{bmatrix} y(k+1|k) \\ y(k+2|k) \\ y(k+3|k) \\ \vdots \\ y(k+N_p|k) \end{bmatrix}$$

空间机械臂给定的参考轨迹序列为:

$$R(k+1) = \begin{bmatrix} r(k+1|k) \\ r(k+2|k) \\ r(k+3|k) \\ \vdots \\ r(k+N_p|k) \end{bmatrix}$$

那么模型预测控制的误差为:

$$E(k+1) = R(k+1) - Y(k+1) = \begin{bmatrix} r(k+1|k) - y(k+1|k) \\ r(k+2|k) - y(k+2|k) \\ r(k+3|k) - y(k+3|k) \\ \vdots \\ r(k+N_p|k) - y(k+N_p|k) \end{bmatrix} = \begin{bmatrix} e(k+1|k) \\ e(k+2|k) \\ e(k+3|k) \\ \vdots \\ e(k+N_p|k) \end{bmatrix}$$

对离散化公式(4.9)在预测时域 N_p 步内的状态序列可递归展开为:

$$\begin{cases} x(k+1|k) = Ax(k|k) + Bu(k|k) + d(k|k) \\ x(k+2|k) = A^2x(k|k) + ABu(k|k) + Bu(k+1|k) + d(k+1|k) \\ \vdots \\ x(k+N_p|k) = A^{N_p}x(k|k) + A^{N_p-1}Bu(k|k) + Bu(k+N_p-1|k) + d(k+N_p|k) \end{cases} \quad (4.10)$$

将式(4.10)以矩阵方式表达为:

$$\begin{bmatrix} x(k+1|k) \\ x(k+2|k) \\ \vdots \\ x(k+N_p|k) \end{bmatrix} = \begin{bmatrix} I \\ A \\ A^2 \\ \vdots \\ A^{N_p} \end{bmatrix} x(k|k) + \begin{bmatrix} 0 & 0 & \cdots & 0 \\ B & 0 & \cdots & 0 \\ AB & B & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ A^{N_p}B & A^{N_p-1}B & \cdots & B \end{bmatrix} \begin{bmatrix} u(k|k) \\ u(k+1|k) \\ \vdots \\ u(k+N_p-1|k) \end{bmatrix} + \begin{bmatrix} d(k|k) \\ d(k+1|k) \\ \vdots \\ d(k+N_p|k) \end{bmatrix} \quad (4.11)$$

通过式(4.11)得到系统的输出量为:

$$X(k+1) = \psi x(k|k) + \sigma U(k) + D \quad (4.12)$$

$$\text{其中 } X(k+1) = \begin{bmatrix} x(k+1|k) \\ x(k+2|k) \\ \vdots \\ x(k+N_p|k) \end{bmatrix}, \quad \psi = \begin{bmatrix} I \\ A \\ A^2 \\ \vdots \\ A^{N_p} \end{bmatrix}, \quad \sigma = \begin{bmatrix} 0 & 0 & \cdots & 0 \\ B & 0 & \cdots & 0 \\ AB & B & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ A^{N_p}B & A^{N_p-1}B & \cdots & B \end{bmatrix},$$

$$U(k) = \begin{bmatrix} u(k|k) \\ u(k+1|k) \\ \vdots \\ u(k+N_p-1|k) \end{bmatrix}, \quad D = \begin{bmatrix} d(k|k) \\ d(k+1|k) \\ \vdots \\ d(k+N_p|k) \end{bmatrix}$$

将空间机械臂关节路径跟踪控制问题描述为带约束的动态优化问题, 选取模型预测控制算法的代价函数为:

$$\min J(k) = \min \left(\sum_{i=1}^{N_p} \|e(k+i|k)\|_P^2 + \sum_{i=1}^{N_p-1} \|\Delta u(k+i|k)\|_Q^2 \right) \quad (4.13)$$

式中 $e(k+i|k) = r(k+i|k) - y(k+i|k)$ 为跟踪误差, $\Delta u(k+i|k) = u(k+i|k) - u(k+i-1|k)$ 为控制输入增量, P 为误差权重矩阵, Q 是控制输入权重矩阵。

满足:

$$\begin{cases} x(k+1) = Ax(k) + Bu(k) + D \\ y(k+1) = Cx(k) \\ u_{\min}(k+i|k) \leq u(k+i|k) \leq u_{\max}(k+i|k), \quad i = 0, 1, 2, \dots, N_p - 1 \\ y_{\min}(k+i|k) \leq y(k+i|k) \leq y_{\max}(k+i|k), \quad i = 0, 1, 2, \dots, N_p \end{cases} \quad (4.14)$$

4.4 基于 RBF 神经网络优化的模型预测控制

空间机械臂的预测模型建立后，为了获取最优控制量 $U(k)$ ，模型预测控制在每一步的控制过程中都需要求解代价函数所表示的一个非线性优化问题，本文利用 RBF 神经网络来对模型预测控制代价函数 J 进行逼近，利用神经网络的非线性逼近能力来加速或替代传统的模型预测控制求解过程。通过与文献[54]相比较，本文所设计的算法在保证空间机械臂系统动态性能的同时达到更优的控制精度。

利用 RBF 神经网络对代价函数 J 进行逼近，将状态 x 和控制输入 u 作为 RBF 神经网络的输入 h ， $h = [x(k)^T \ U(k)^T]^T$ ，则 RBF 神经网络的理想输出为：

$$\hat{J} = W^T \cdot \varphi(h) + \varepsilon \quad (4.15)$$

RBF 神经网络采用高斯径向基函数， $\varphi_i(h) = \exp\left(-\frac{\|h - c_i\|^2}{2\sigma_i^2}\right)$ ， W 为权重向量，

$W = [w_1 \ w_2 \ \dots \ w_m]^T$ ， ε 为逼近误差。

通过链式法则分解梯度：

$$\frac{\partial \hat{J}(k)}{\partial U(k)} = \frac{\partial \hat{J}(k)}{\partial \varphi} \frac{\partial \varphi}{\partial h} \frac{\partial h}{\partial U(k)}$$

构建完整雅可比矩阵 $G(k)$ ：

$$G(k) = \begin{bmatrix} \frac{\partial y(k+1)}{\partial u(k)} & 0 & \dots & 0 \\ \frac{\partial y(k+2)}{\partial u(k)} & \frac{\partial y(k+2)}{\partial u(k)} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial y(k+N_p)}{\partial u(k)} & \frac{\partial y(k+N_p)}{\partial u(k+1)} & \dots & \frac{\partial y(k+N_p)}{\partial u(k+N_p-1)} \end{bmatrix}$$

$$\text{取 } g(k) = \begin{bmatrix} \frac{\partial y(k+1)}{\partial u(k)} & \frac{\partial y(k+2)}{\partial u(k)} & \dots & \frac{\partial y(k+N_p)}{\partial u(k)} \end{bmatrix}。$$

利用梯度下降算法对模型预测控制优化代价函数 J 进行寻优，记 $\Delta U(k) = [\Delta u(k) \ \Delta u(k+1) \ \dots \ \Delta u(k+N_p-1)]$ ，则

$$\begin{aligned} U(k+1) &= U(k) - \eta \frac{\partial \hat{J}(k)}{\partial U(k)} \\ &= U(k) + \eta Q G^T(k) E(k) - \eta P(k) \Delta U(k) \end{aligned} \quad (4.16)$$

η 为 RBF 神经网络梯度下降法的自适应优化律, $\Delta U(k)$ 可以表示为:

$$\Delta U(k) = \frac{\eta P}{I + \eta Q} g^T(k) \cdot E(k) \quad (4.17)$$

综上, RBF-MPC 的控制增量 $\Delta U(k)$ 具有如下形式:

$$\Delta U(k) = \eta g^T(k) \cdot E(k) \quad (4.18)$$

在空间机械臂轨迹控制过程中使 J 达到最小或 $U(k)$ 不再变化, 此时将 $U(k)$ 作为最优控制量作用到空间机械臂系统实施控制。

自适应优化律 η 在实时控制过程能够自适应调整, $\eta = \frac{\beta}{\lambda_{\max}(g(k)g^T(k))}$, 其中 $0 < \beta < 2$, $\lambda_{\max}$ 是 $(g(k)g^T(k))$ 的最大特征值。

为了训练 RBF 神经网络, 采用平方误差损失函数 $L(W)$ 来衡量神经网络输出 $\hat{J}$ 与目标代价函数 J 之间的误差。

$$L(W) = \frac{1}{N_p} \sum_{i=1}^{N_p} (\hat{J}(i) - J(i))^2 \quad (4.19)$$

则由梯度下降法得到 RBF 神经网络权重自适应更新律为:

$$W(k+1) = W(k) + \eta \nabla L(W) \quad (4.20)$$

式中 $\nabla L(W)$ 是关于输出层权重的梯度向量。

4.5 RBF 模型预测控制稳定性分析

定理 4.1: 对于具有约束条件(4.14)的空间机械臂系统(4.1), 采用基于 RBF 神经网络优化的模型预测控制器(4.16), 能够保证空间机械臂轨迹跟踪误差是渐近收敛的。

证明: 选择李雅普诺夫函数为:

$$V = E^T(k)E(k) \quad (4.21)$$

$$\begin{aligned} \Delta V &= V(k+1) - V(k) \\ &= E^T(k+1)E(k+1) - E^T(k)E(k) \\ &= [E^T(k) + \Delta E^T(k)][E(k) + \Delta E(k)] - E^T(k)E(k) \\ &= \Delta E^T(k)[2E(k) + \Delta E(k)] \end{aligned}$$

由 $E(k) = Y(k+1|k) - R(k+1|k)$ 得:

$$\frac{\partial E(k)}{\partial U(k)} = -\frac{\partial y}{\partial u(k)} = -g(k)$$

$$\Delta E(k) = \frac{\partial E(k)}{\partial U(k)} \cdot \Delta U(k) = -\eta g^T(k) g(k) E(k) \quad (4.22)$$

$$\begin{aligned} \Delta V &= \Delta E^T(k) [2E(k) + \Delta E(k)] \\ &= -\eta g^T(k) g(k) E(k) \cdot [2E(k) - \eta g^T(k) g(k) E(k)] \\ &= -\eta g^T(k) g(k) E(k) \cdot [2I - \eta g^T(k) g(k)] E(k) \end{aligned}$$

由于 $0 < \eta < \frac{\beta}{\lambda_{\max}(g(k)g^T(k))}$ ，因此 $\Delta V(k) \leq 0$ ，即 $\lim_{k \rightarrow \infty} E(k) = 0$ 。

因此，根据李雅普诺夫稳定性判据得空间机械臂系统的轨迹跟踪误差是收敛的。

4.6 仿真实验

对空间机械臂系统的仿真由两部分组成：一部分是控制器模型的仿真，一部分是被控对象模型的仿真。借助于 Simulink 库中 Gazebo Co-Simulink 的通信模块，实现 Simulink 与 Gazebo 闭环数据交换^[55]，使 Gazebo 和 Simulink 协同工作，搭建联合仿真平台，仿真模型如图 4.1 所示。




图4.1 空间机械臂仿真模型

Fig. 4.1 Space manipulator simulation model

空间机械臂的模型参数为： $m_1 = 2.04 \text{ kg}$ ， $m_2 = 1 \text{ kg}$ ， $l_1 = 1 \text{ m}$ ， $l_2 = 0.87 \text{ m}$ 。令 $p_1 = (m_1 + m_2)l_1^2$ ， $p_2 = m_2 l_2^2$ ， $p_3 = m_2 l_1 l_2$ ， 则

$$M(q) = \begin{bmatrix} p_1 + p_2 + 2p_3 \cos q_2 & p_2 + p_3 \cos q_2 \\ p_2 + p_3 \cos q_2 & p_2 \end{bmatrix}$$

$$C(q, \dot{q}) = \begin{bmatrix} -p_3 \dot{q}_2 \cos q_2 & -p_3 (\dot{q}_1 + \dot{q}_2) \cos q_2 \\ -p_3 \dot{q}_1 \cos q_2 & 0 \end{bmatrix}$$

$$F(\dot{q}) = 0.02 \operatorname{sgn}(\dot{q})$$

$$\tau_d = \begin{bmatrix} 0.01 \sin(t) \\ 0.01 \sin(t) \end{bmatrix}$$

$$p = [p_1, p_2, p_3] = [2.9, 0.76, 0.87]$$

输入期望轨迹为 $q_d(t) = [0.1 \sin(t) \quad 0.1 \sin(t)]^T$ ，输入变量的约束条件是 $0 \leq u \leq 30$ ，输出变量的约束条件是 $-0.105 \leq y \leq 0.105$ 。

对在空间机械臂进行 MATLAB 实验仿真进行模型实验，实现空间机械臂的实时闭环控制，为了验证所设计控制方案的优越性，在仿真实验中将 MPC 和 RBF-MPC 控制算法进行对比，两种控制方案使用相同的机械臂的参数来实现公平性。空间机械臂 RBF 神经网络模型预测控制的仿真实验结果如图 4.2-4.6 所示




图4.2 RBF模型预测控制位置跟踪

Fig. 4.2 RBF model predictive control position tracking




图4.3 空间机械臂的轨迹跟踪误差

Fig. 4.3 Trajectory tracking error of space manipulator

图 4.2 展示了空间机械臂在 RBF 模型预测控制的位置跟踪效果。这里绿线代表期望的位置，蓝线代表模型预测控制方案空间机械臂的位置，红线代表 RBF-MPC 控制方案的空间机械臂的位置。由波形可知，在两种控制方案下空间机械臂均按照预定的期望轨迹进行平稳运动，关节调节时间较少，实际位置在较短的时间内跟踪期望位置，运行稳定后关节 1、2 跟踪误差较小。相较于 MPC 控制方案，RBF-MPC 方案的轨迹跟踪误差减少了 70%，轨迹跟踪时间减少了 37%，验证了 RBF-MPC 控制方案有着更快的跟踪速度和更小的跟踪误差。

图 4.3 展示了空间机械臂轨迹跟踪的误差，蓝线代表 MPC 控制方案的误差值，黄线代表 RBF-MPC 控制方案的误差值。由图 4.3 分析可得，两种控制方案的位置跟踪在初始阶段均有一定误差，RBF-MPC 控制方案能在更短时间内跟踪上期望的位置，减少 70%的轨迹跟踪误差；且 RBF-MPC 控制方案在系统稳定后可以减少跟踪误差，缩短跟踪时间，实现更快、更稳定的空间机械臂跟踪。




图4.4 RBF模型预测控制位置跟踪

Fig. 4.4 RBF model predictive control speed tracking

图 4.4 是空间机械臂在 RBF 模型预测控制的速度跟踪效果。红线代表期望的位置，绿线代表模型预测控制方案空间机械臂的位置，蓝线代表 RBF-MPC 控制方案的空间机械臂的位置。两种控制方法的速度跟踪在初始阶段存在一定的误差，但是能够在短时间内跟踪上期望的速度，相较于 MPC 控制方案，RBF-MPC 方案减少了速度跟踪时间，降低了速度跟踪的误差，验证了 RBF-MPC 控制方案有着更快的跟踪速度和更小的跟踪误差，RBF-MPC 控制策略可以减少振荡现象，可以实现更快、更稳定的速度跟踪。


图4.5 代价函数 J 变化图Fig. 4.5 Cost function J variation diagram

图 4.5 表示为对代价函数 J 的求值, 蓝线代表 MPC 控制方案的代价函数值, 黄线代表 RBF-MPC 控制方案的代价函数值。由图 4.5 分析可得, 相较于 MPC 控制方案, RBF-MPC 控制方案能求解出更小的代价函数, 更快的实现控制输入的最优化, 从而获取最优的控制输入来实现空间机械臂的轨迹跟踪控制。




图4.6 空间机械臂的控制力矩

Fig. 4.6 Control torque of space manipulator

图 4.6 表示为对空间机械臂的控制输入力矩对比, 蓝线代表 MPC 控制方案的输入力矩, 黄线代表 RBF-MPC 控制方案的输入力矩。由图 4.6 分析可得, 相较于 MPC 控制方案, RBF-MPC 控制方案得到的控制输入比较平稳, 并且所耗能量减少 65%, 更有利于空间机械臂的工作需求。

4.7 本章小结

本章节针对存在外部扰动与动态约束的空间机械臂系统, 提出了一种基于 RBF 神经网络的模型预测控制算法, 来实现空间机械臂的轨迹跟踪控制问题。本算法使模型预测代价函数最优化、最小化来获得最优的控制输入, 从而实现空间机械臂系统快速稳定的关节轨迹跟踪。而后在 MATLAB 平台进行仿真验证, 结果表明在空间机械臂存在建模不确定性和条件约束的情况下, RBF-MPC 控制器可以有效降低每个关节轨迹跟踪的误差, 显著减少系统的响应时间, 使系统更快达到稳定状态, 且 RBF-MPC 控制器得到的控制输入比较平稳, 所耗能量更少。综上所述, 所设计的 RBF-MPC 控制器具有更优的控制效果, 验证了所提控制算法的有效性。

5 结论和展望

5.1 结论

本文主要基于自适应神经网络控制算法、模糊神经网络和模型预测控制理论研究了参数不确定的空间机械臂系统的轨迹跟踪控制问题。本文针对空间机械臂轨迹跟踪提出了两种方法,第一种是针对存在输入死区的空间机械臂轨迹跟踪问题,提出了一种基于模糊 RBF 神经网络的控制算法。第二种是提出了一种基于神经网络优化的 MPC 控制算法。主要包括:

(1) 介绍了本文的主要研究内容,对空间机械臂的国内外发展历程、发展趋势以及轨迹跟踪研究现状作了详细阐述。

(2) 通过拉格朗日方法建立了刚性双连杆空间机械臂的动力学模型,详细介绍了本文用于机械臂控制的 RBF 神经网络控制、模糊 RBF 神经网络、模型预测控制等理论基础及在机械臂控制中的应用。

(3) 在空间机械臂动力学方程的基础上,针对存在输入死区且受外部干扰的空间机械臂轨迹跟踪问题,提出了一种基于模糊 RBF 神经网络的控制算法。该算法分为两部分,其一是使用模糊神经网络逼近空间机械臂系统模型的不确定项与未知干扰;其二是采用模糊神经网络逼近并补偿输入死区;设计了控制律和自适应律,并通过李雅普诺夫函数方法证明了空间机械臂系统的稳定性;最后对空间机械臂进行仿真实验,实验结果验证了所设计控制器的有效性,克服输入死区实现了空间机械臂精确的轨迹跟踪控制。

(4) 在空间机械臂的动力学方程基础上,针对具有输入输出约束的空间机械臂轨迹跟踪控制,提出了一种基于 RBF 神经网络的模型预测控制算法。首先通过模型预测控制将空间机械臂的轨迹跟踪控制转化为动态优化问题;其次在经典的模型预测控制基础上,采用 RBF 神经网络逼近和最小化模型预测控制的代价函数来优化空间机械臂的轨迹跟踪控制,实现基于模型预测控制的最优控制输入;然后通过李雅普诺夫稳定性理论证明了所提控制算法的稳定性;最后仿真结果验证了所提控制算法的有效性。即使存在输入输出约束,所设计的 RBF 神经网络模型预测控制器也能保证空间机械臂的最优轨迹跟踪控制。

(5) 对本文的主要工作和创新点进行总结,对未来的工作进行展望。

5.2 创新点

本文针对受外部扰动影响且参数不确定的空间机械臂系统进行了轨迹跟踪控制研究。利用自适应模糊神经网络控制方法对存在输入死区的空间机械臂轨迹跟踪控制展开了讨论;针对空间机械臂系统存在的模型误差和输入输出约束问题,提出了一种基于自

适应 RBF 神经网络的模型预测控制算法。利用自适应神经网络控制方法、模型预测控制理论、李雅普诺夫函数方法对空间机械臂系统的轨迹跟踪控制展开了研究。

本文的主要贡献在于三个方面：

(1) 将模糊神经网络用于空间机械臂系统，使用模糊神经网络逼近空间机械臂系统模型的不确定项与未知干扰，克服空间机器人在工程实践中难以获得准确数学模型的问题。

(2) 利用模糊神经网络的逼近特性来处理空间机械臂的输入死区，设计了模糊神经网络控制器逼近并补偿输入死区。

(3) 通过设置代价函数及约束条件将轨迹跟踪问题转化成模型预测控制的规划问题，利用 RBF 神经网络逼近模型预测控制的代价函数，求解更优的控制输入，提高系统跟踪的稳定性和准确性。

5.3 展望

对于空间机械臂的轨迹跟踪控制问题的研究提出以下一些展望性的工作：

(1) 本文中的研究聚焦于刚性二连杆空间机械臂系统的建模与控制，尚未涉及柔性的空间机械臂动力学分析，并且鉴于工业应用场景普遍采用高自由度多关节联动机械臂系统。未来将对柔性多自由度的空间机械臂进行研究探讨。

(2) 在空间机械臂执行在轨任务过程中，系统可靠性面临着执行机构突发性故障引发的控制性能退化甚至任务失效风险。后续研究将聚焦于构建融合多模态故障诊断与主动补偿机制的智能容错控制架构，以提升复杂故障模式下的系统稳定性。

(3) 本研究提出的控制策略现阶段研究范畴限定于 MATLAB 数值仿真验证平台，暂未进行过实物空间机械臂上的实验仿真，在未来的研究中重点开展控制算法在动态特性测试、扰动抑制等方面的机械臂实物验证工作。

参考文献

- [1] 薛智慧,刘金国. 空间机械臂操控技术研究综述[J]. 机器人,2022,44(01):107-128.
- [2] 薛福峰,樊宇,张鑫,等. 深海绳驱动蛇形机械臂运动学控制研究[J]. 机电工程,2023,40(04):522-527+570.
- [3] Wang L , Chen K , Franco E. Robust and Adaptive Control of a Soft Continuum Manipulator for Minimally Invasive Surgery[J]. Robotics, 2024, 13(11):162-162.
- [4] 张志宇. 智能仓储搬运设备的人机协同设计与优化研究[J]. 中国机械,2023,(31):16-19.
- [5] 于登云,潘博,马超. 星球探测机器人研究现状与发展展望[J]. 宇航学报,2023,44(04):633-643.
- [6] 张国亮. 空间机器人遥操作中基于视觉的局部自主控制研究[D]. 黑龙江: 哈尔滨工业大学,2010.
- [7] 张欧阳. 自由飞行空间机器人目标捕获运动规划与控制研究[D]. 黑龙江: 哈尔滨工业大学,2022.
- [8] 郭睿,朱超. “天宫”上的机械臂[J].科学世界,2023,(04):8-11.
- [9] 罗艳妮,郭亚红. 基于改进 PID 的核算机器人机械臂控制研究[J]. 自动化与仪器仪表,2023,(05):212-215.
- [10] 周志勇,莫非,赵凯,等. 基于 PPO 的自适应 PID 控制算法研究[J]. 系统仿真学报,2024,36(06):1425-1432.
- [11] 丁荣乐,侯旋,孙文建. 考虑变有效载荷的机械臂自适应 PID 控制[J]. 机电工程,2022,39(03):291-299.
- [12] 刘福才,刘林,徐智颖. 柔性关节空间机械臂奇异摄动模糊 PID 控制仿真研究[J]. 高技术通讯,2019,29(07):661-667.
- [13] 贾立蒙,侯明. 基于自适应参数趋近律的机械臂滑模控制[J]. 机床与液压,2024,52(23):51-57.
- [14] 范亚洲,孙林祥,白雪剑,等. 基于自适应反正切非奇异终端滑模的水下机械臂轨迹跟踪控制[J]. 控制与决策,2025,40(01):205-213.
- [15] Zhang X , Wang R. Non-singular fast terminal sliding mode control of robotic manipulator with prescribed performance[J]. Journal of Engineering and Applied Science, 2024, 71(1):217-217.
- [16] Guo K , Zhang H , Wei C , et al. Novel sliding mode control of the manipulator based on a nonlinear disturbance observer[J]. Scientific Reports, 2024, 14(1):30656-30656.
- [17] 尚东阳,李小彭,尹猛,等. 采用 RBF 神经网络辨识的柔性机械臂抑振控制策略[J]. 西安交通大学学报,2022,56(06):76-84.
- [18] 梁相龙,姚建勇. 带有输出约束的液压机械臂自适应神经网络力跟踪控制[J]. 控制理论与应用,2025,42(01):138-148.
- [19] 李小彭,付嘉兴,刘海龙,等. 柔性空间机械臂 RBF 神经网络补偿滑模控制策略[J]. 东北大学学报(自然科学版),2024,45(09):1258-1267.
- [20] Yang X , Zhao Z , Li Y , et al. Adaptive neural network control of manipulators with uncertain kinematics and dynamics[J]. Engineering Applications of Artificial Intelligence, 2024, 133:107935-107935.
- [21] Weiying X. Parameter-Tunable RBF Neural Network Control Facing Dual-Joint Manipulators[J]. Journal of Robotics, 2022, 2022, 1-10.
- [22] 丁萌,顾秀涛,郑先杰,等. 基于模糊补偿的连续型空间机械臂预定时间控制[J]. 浙江大学学报(工学版),2022,56(06):1175-1180.
- [23] 刘东博,陈力. 基于模糊逻辑的双臂空间机器人在轨辅助对接操作变结构力/位控制[J]. 机械工程

- 学报,2025,61(01):60-70.
- [24] Lai G , Zou S , Xiao H , et al. Fixed-time adaptive fuzzy control with prescribed tracking performances for flexible-joint manipulators[J]. Journal of the Franklin Institute, 2024, 361(7):106809-106809.
- [25] Fang L , Zheng Z , Yang W , et al. Improved fuzzy sliding mode control in flexible manipulator actuated by PMAs[J]. Robotica,2022,40(8):2683-2696.
- [26] Wang J , Zhao B , Xue R , et al. Robust adaptive fuzzy control for uncertain robotic manipulators with full state constraints[J]. Journal of Physics: Conference Series, 2024, 2902(1):012047-012047.
- [27] Haoran F , Yuxiang W , Tian X , et al. Prescribed-time adaptive neural tracking control for a class of uncertain robotic manipulators with dead zone input[J]. Nonlinear Dynamics, 2022, 110(1):497-512.
- [28] Jinmiao S , Wenhui Z , Shuhua Z , et al. Fuzzy Adaptive Compensation Control for Space Manipulator with Joint Flexibility and Dead Zone Based on Neural Network[J]. International Journal of Aeronautical and Space Sciences, 2023, 24(3):876-889.
- [29] Wang F , Liu Z , Lai G. Fuzzy adaptive control of nonlinear uncertain plants with unknown dead zone output[J]. Fuzzy Sets and Systems, 2015, 263:27-48.
- [30] 吕芳芳,楼旭阳,叶倩. 具有死区非线性输入的柔性臂自适应边界控制[J]. 扬州大学学报(自然科学版),2024,27(05):16-24.
- [31] Yi H , Songyi D , Rui G , et al. Observer-based dynamic surface control for flexible-joint manipulator system with input saturation and unknown disturbance using type-2 fuzzy neural network[J]. Neurocomputing, 2021, 436:162-173.
- [32] 刘育强,魏庆生,李浩然,等. 基于径向基函数神经网络的空间漂浮机械臂装配控制[J]. 哈尔滨工程大学学报,2023,44(05):831-836.
- [33] Aro K , Guevara L , Torriti T M , et al. Robust Nonlinear Model Predictive Control for the Trajectory Tracking of Skid-Steer Mobile Manipulators with Wheel - Ground Interactions[J]. Robotics,2024,13(12):171-171.
- [34] Krämer M , Rösmann C , Hoffmann F , et al. Model predictive control of a collaborative manipulator considering dynamic obstacles[J]. Optimal Control Applications and Methods,2020,41(4):1211-1232.
- [35] Abdelhadi A , Kamel K , Mohamed B , et al. Constrained Neural Network Model Predictive Controller Based on Archimedes Optimization Algorithm with Application to Robot Manipulators[J]. Journal of Control, Automation and Electrical Systems, 2023, 34(6):1159-1178.
- [36] Kang E , Qiao H , Gao J , et al. Neural network-based model predictive tracking control of an uncertain robotic manipulator with input constraints[J]. ISA Transactions, 2021, 109:89-101.
- [37] Dawei G. Kinematics modeling of redundant manipulator based on screw theory and Newton-Raphson method[J]. Journal of Physics: Conference Series, 2022, 2246(1):012068-012068.
- [38] 孙占庚,金国光,常志,等. 基于 Kane 法的柔性机械臂系统动力学建模及其模态截取研究[J]. 天津工业大学学报,2009,28(04):61-63.
- [39] Sengalani R , Mohideen R S. Numerical Analysis of Robotic Manipulator Subject to Mechanical Flexibility by Lagrangian Method[J]. Proceedings of the National Academy of Sciences, India Section A: Physical Sciences, 2019, 90(3):1-11.
- [40] Qijia Y. Adaptive fuzzy neural network control for a space manipulator in the presence of output constraints and input nonlinearities[J]. Advances in Space Research, 2021, 67(6): 1830-1843.
- [41] 芮宏斌,曹伟,孙宁宁. 基于 BP 神经网络的光伏阵列清洁机械臂逆运动学分析与时间最短运动规划[J]. 太阳能学报,2022,43(10):43-51.
- [42] Xu Q , Ju W , Lin Y , et al. Research on Positioning Error Compensation of Rock Drilling Manipulator

- Based on ISBOA-BP Neural Network[J]. *Applied Sciences*, 2024, 14(18):8480-8480.
- [43] 李琦琦,徐向荣,张卉. 基于自适应神经网络的机械臂滑模轨迹跟踪控制[J]. *工程设计学报*,2023,30(04):512-520.
- [44] 李正楠,张锦,殷玉枫,等. 多关节机械臂的分数阶滑模变结构神经网络自适应控制[J]. *机械科学与技术*,2021,40(02):270-275.
- [45] 高阳,张晓晖,高玉儿,等. 基于神经网络和模糊补偿的水下机械臂控制[J]. *计算机工程与应用*,2022,58(15):317-323.
- [46] 辛旗,白蕾,孟娇娇. 基于自适应模糊神经网络的机械臂控制[J]. *自动化与仪器仪表*,2019,(11):37-40.
- [47] Yan Y , Jong R W. Design of Adaptive Fuzzy-Neural-Network-Imitating Sliding-Mode Control for Parallel-Inverter System in Islanded Micro-Grid[J]. *IEEE ACCESS*, 2021, 9:56376-56396.
- [48] Xin Z ,Ying Q .Fuzzy Sliding Mode Control of Manipulator Based on Disturbance Observer and RBF Neural Network[J].*Automatic Control and Computer Sciences*, 2023, 57(2):123-134.
- [49] Chen W , Ge S S , Wu J ,et al.Globally Stable Adaptive Backstepping Neural Network Control for Uncertain Strict-Feedback Systems With Tracking Accuracy Known a Priori[J].*IEEE Transactions on Neural Networks and Learning Systems*, 2015, 26(9):1842-1854.
- [50] 胡飘,张丽,杨阔竣,等. 基于模型预测的膝关节置换手术机器人柔顺控制[J]. *工程科学学报*,2024,46(09):1638-1646.
- [51] 汪正涛,陶卫军. 基于模型预测控制与阻抗控制的受限机构操作方法[J]. *兵工自动化*,2024,43(10):68-75.
- [52] Yan J , Jin L , Hu B. Data-Driven Model Predictive Control for Redundant Manipulators With Unknown Model[J]. *IEEE transactions on cybernetics*, 2024, 2024,1-11.
- [53] Zhang Z, Wang X, Jing X. Robust Amplitude Control Set Model Predictive Control With Low-Cost Error for SPMSM Based on Nonlinear Extended State Observer[J]. *IEEE Transactions on Power Electronics*, 2024, 39(6):7016-7028.
- [54] 梅满,朱大奇,甘文洋,等. 基于模型预测控制的水下机器人轨迹跟踪[J]. *控制工程*,2019,26(10):1917-1924.
- [55] 张蕾,李义帅,王晓华,等. 联合仿真下机械臂终端约束模型预测控制方法[J]. *西安工程大学学报*,2022,36(04):118-126.